作品编号：（报名时系统提供的作品编号）

2026 年（第十二届）全国大学生统计建模大赛参赛 作 品

参赛学校：暨南大学

论文题目：非线性交互特征与破产风险：基于 SIS-SCAD 框架的实证分析

参赛队员：叶伟丰 崔雅格 李宗昊

指导老师：姜云卢

非线性交互特征与破产风险：基于 SIS-SCAD 框架的实证分析

摘要

2025 年政府工作报告明确指出要积极防范金融领域风险并推进企业风险处置与转型发展。在此宏观导向下建立有效的企业破产预测机制对于优化市场资源配置与维护金融稳定具有不可替代的作用。然而，当前传统信用预警模型过度依赖低维线性的财务指标体系**难以有效捕捉复杂真实经济环境中的非线性阈值效应与高阶交互作用**，且在面对极度不平衡的破产样本时极易陷入**预警失效**困境。

针对底层数据的特征重构是突破上述方法论局限的关键所在。为高效捕捉交互与阈值效应，本研究首先结合经典杜邦分析法对数据进行**经济学模块化分类**。随后采用**自然三次样条**对变量进行非参数展开并实施**块状张量积交叉**。这一显式构造超高维特征空间的设计为后续成功捕捉到具有实际经济意义的潜在高阶交互项与非线性阈值效应从而为后续的高维统计推断奠定了坚实的数据基础。

本文在核心**白盒算法**层面提出并应用 **GCor-SIS-REDS-MDS** 算法以应对超高维特征空间带来的维数灾难与假阳性难题。该算法不仅具备 **FDR 控制功能**，更展现出对极端财务异常值的稳健性。该主要模型架构引入多重数据拆分机制确保特征筛选的稳健性并严格控制错误发生率，随后串联融合**代价敏感权重的 SCAD 惩罚逻辑回归**。此外本文同步构建了处理不平衡样本表现优异的 **LightGBM** 模型作为泛化误差基准用于评估主模型在换取宏观政策可解释性时付出的性能损耗。

本文最终得出的实证结论表明，主要模型从海量交叉项中精准锁定了 16 个核心驱动因子，其中 8 个特征显著，证实企业破产并非单一维度的衰退而是**以杠杆为枢纽的多重财务恶化非线性共振**。在预测效能方面该统计模型展现出卓越的区分能力，其 ROC-AUC 达到 0.938 且 KS 统计量高达 0.7638。代价敏感转移分析进一步量化证实漏报一家破产企业的代价是误杀一家健康企业代价的 30.5 倍。最终基于该模型构建银行贷款最优决策器实现在不同情境下给出利润最大化的最优决策，如在无抵押且 5%利率情境下可实现净利润 3510 万元而在 6%利率且 40%违约损失率情境下净利润可达 8944 万元，切实为防范系统性金融风险提供了精准的**量化风控工具**。

关键词： 企业破产预测　超高维特征筛选　SCAD 惩罚回归　非线性交互效应

目录

一、 引言 7
1.1 研究背景 7
1.2 研究现状 7
二、 研究思路 8
2.1 战略导向与问题提出 8
2.2 双模型框架与宏观战略映射 8
三、 模型假设与符号说明 9
3.1 基本假设 9
3.2 符号说明 9
四、 探索性分析 9
4.1 数据获取与处理 9
4.2 数据探索性分析 10
五、 主要模型 12
5.1 模型建立 12
5.1.1 特征工程 12
5.1.2 GCor-SIS-REDS-MDS 算法 16
5.1.3 平滑切片绝对偏度（Smoothly Clipped Absolute Deviation, SCAD） 18
5.2 模型求解 19
六、 次要模型 26
6.1 模型建立 26
6.2 模型求解与评估 27
七、 模型评估与对比 28
八、 主要模型的评价与推广 30
8.1 模型的优点 30
8.2 模型的不足 30

8.3 模型的推广 30
九、 结论 31
十、 致谢 32
附录 35

图目录

图 1 类别横向堆积柱形图 10
图 2 全部特征相关性热力图 11
图 3 相关性 Top15 特征与目标变量相关性热力图 11
图 4 相关性最强 15 个特征关于目标变量的类别条件分布图 12
图 5 Gam 平滑曲线图 13
图 6 类别平均相关性系数热力图 14
图 7 各类内特征与目标变量相关性箱线图 15
图 8 逻辑回归拟合图 15
图 9 GCor-SIS-REDS 算法流程图 17
图 10 特征筛选频率直方图 20
图 11 最终有效特征及其系数条形图（特征名称映射详见下表） 20
图 12 Bootstrap 后选择推断可视化结果图 23
图 13 主模型评估组合图 24
图 14 各情况下最优决策示意图 26
图 15 SHAP 蜂窝图 27
图 16 LightGBM 模型评估组合图 28

表目录

表 1 符号说明 9
表 2 特征分类表 14
表 3 特征名称映射表 21
表 4 后选择推断结果表 22
表 5 模型评估参数对比表 29

一、 引言

1.1 研究背景

防范化解重大金融风险是国家安全的重要组成部分，党的二十大报告明确提出“守住不发生系统性风险底线”。21 世纪的当今，**有效预测与防范金融系统性风险尤为关键**。2025 年《政府工作报告》强调要“积极防范金融领域风险，按照市场化、法治化原则，一体推进地方中小金融机构风险处置和转型发展”[1]。企业破产作为市场风险出清的关键机制，在优化资源配置、维护金融稳定中发挥着不可替代的作用。

为完善市场主体退出机制，国家层面持续推进制度创新。国务院**《关于开展营商环境创新试点工作的意见》**（国发〔2021〕24 号）明确提出“推行破产预重整制度，建立健全企业破产重整信用修复机制”[2]；国家发展改革委等 13 部委联合印发的**《关于推动和保障管理人在破产程序中依法履职 进一步优化营商环境的意见》**（发改财金规〔2021〕274 号）要求加快“僵尸企业”出清，建立跨部门信息共享机制[3]。二十届三中全会《决定》更从全面深化改革高度，要求“健全企业破产机制”[4]。

在此背景下，本文立足**“服务国家战略、创新统计赋能”**主题，针对企业破产预测中的阈值与交互项特征提取难题，提出一种创新统计模型。通过构建精准高效的破产风险预警模型，为金融监管部门提供早期识别工具，为防范化解重大金融风险、优化营商环境提供统计支撑，切实服务国家治理体系和治理能力现代化。

1.2 研究现状

企业破产研究始于 Beaver(1966)的单变量分析[5]，随后 Altman(1968)的 Z-score 模型[6]与 Ohlson(1980)的 Logistic 回归模型[7]奠定了该领域的基础。早期模型多依赖低维财务指标的线性组合构建预警机制。随着市场环境复杂化，线性假设局限显现，例 Grice 等(2003)发现早期模型的部分变量在远期破产预测中缺乏统计显著性[8]。此外，上述方法缺少对大量财务交互项的深入研究。

针对于交互项带来的高维特征向量空间，LASSO[9]、岭回归[10]以及 MCP[11]等正则化方法被广泛引入，以缓解多重共线性并实现变量筛选。例如，Tian 等(2015)与杨青龙等(2016)均在企业财务问题上证实了 LASSO 惩罚提取关键指标的有效性[12,13]。然而，

LASSO 面对高度相关的财务指标簇时易随机截断，且对大系数的过度惩罚会导致参数估计有偏，难以稳定刻画特征协同风险；此外，对于非线性阈值效应亦缺少讨论。

Liang 等 (2016) 证实了多维异质性特征融合对提升预测效能的关键作用[14]，促使大量后续研究引入机器学习乃至深度学习算法（如 SVM[15]，随机森林[16]，BP 神经网络[17]，XGBoost[18]）。尽管如此，正如 Qiu 等(2020)指出，现有研究仍面临精度与可解释性难以兼顾的困境：传统线性模型难以捕捉非线性阈值效应与复杂协同机制；而机器学习虽能隐式处理高阶交互，却因缺乏统计透明度，难以转化为明确的监管红线[19]。

兼顾**非线性交互捕捉与经济学可解释性系亟待填补的空白**。区别于隐式黑盒与传统有偏正则化，本文通过**自然三次样条**与**模块化交叉**，显式构造涵盖阈值效应与高阶交互的超高维特征空间；**进而引入具 FDR 控制的 SIS 筛选并联立 SCAD 模型**，有效克服 LASSO 估计偏差。该框架实现了复杂违约特征的无偏稀疏提取，在大幅提升非线性预测精度的同时，确保了风险驱动因子的精确可解释性。

二、 研究思路

2.1 战略导向与问题提出

本文立足于“**防范化解系统性重大金融风险**”的国家战略背景。微观企业的财务违约与破产是诱发宏观系统性风险的源头。然而，传统的企业信用预警模型多依赖于低维、线性的财务指标体系，难以有效捕捉复杂经济环境下财务恶化的非线性阈值效应与交互项引起的高阶数据维度灾难。同时，极度不平衡的破产样本分布使得常规模型面临严重的预警失效困境。为此，本文致力于通过底层特征空间的重构与高维统计算法的创新，打破传统线性假设的桎梏，为金融安全提供量化赋能。

2.2 双模型框架与宏观战略映射

本文主要包含两大模型体系：

1. 主模型（SIS-SCAD 白盒架构）

该模型兼顾预测精度与极强的经济学可解释性，遵循非线性特征构造—大规模降维—自适应筛选逻辑路径：依托杜邦分析法与大语言模型，将基础财务变量划分为盈利、杠杆等经济模块；运用自然三次样条对基础变量进行非参数展开，并实施模块间定向块状张量积交叉，显式构造具经济意义的超高维交互特征空间；串联 SIS 与 SCAD 惩罚逻

辑回归，依次实现特征空间初步降维、多重共线性消解及变量自适应收缩。最后通过数学与统计方法对结果进行说明与分析。

2. 次要模型（纯黑盒模型）：基于 LightGBM 算法。

该模型作为全篇性能基准，无结构性约束，直接基于原始财务数据逼近泛化误差极限，旨在量化主模型在获取宏观政策可解释性时所付出的精度折损代价。

最终，本文通过 AUC 与 F1-score 等多重维度对双模型进行深度剖析。研究旨在将抽象的高维统计筛选结果还原为具象的经济学逻辑，为监管部门提供高灵敏度的数字化预警工具，前置化解实体经济债务风险。

三、 模型假设与符号说明

3.1 基本假设

(1) 关系式 $\begin{cases} C_1:\min\limits_{j\in\mathcal{A}} h_j \geq 2c_1 n^{-\kappa}, c_1>0 \ and \ 0<\kappa<\dfrac{1}{2} \\ C_2:\log p = o\left(n^{1-2\kappa}\right) \end{cases}$ ， 成立

(2) 假设所有企业样本是独立同分布的。

(3) 数据统计时不存在误差，且异常值基本由破产企业自身特征所引起。

3.2 符号说明

表1 符号说明

符号	含义
p	特征维度
q	目标变量维度
r	相关系数
X_r	第r项特征
Y	目标变量
M	均值
S	标准差
ω	边际相关系数/权重
$a\vee b$	取 a 和 b 间的最大值
$\#$	集合内点的数量

四、 探索性分析

4.1 数据获取与处理

本论文数据集源自 kaggle 网站的 Company Bankruptcy Prediction 数据集（获取网址：https://www.kaggle.com/code/ahmedtronic/company-bankruptcy-prediction）。该数据收集自 1999 年至 2009 年的《台湾经济杂志》，描述了多家企业的各种指标以及是否破产。公司破产的定义基于台湾证券交易所的营业法规。该数据集共有 6819 条数据，95 个财务特征，1 个描述是否破产的特征。

该数据集不存在空值，无需进行填空处理。在常规的实证研究与数据挖掘中，通常采用缩尾或截断等方法处理极端异常值，以满足传统线性模型对正态性与方差齐性的假设。然而，在系统性金融风险与企业破产预警这一特定领域，财务指标的异常值（如极高的杠杆率）往往并非统计噪声，而是诱发公司破产的最核心先兆信号，为最大程度保留微观经济主体的真实财务崩塌轨迹，本文决定放弃对连续财务变量进行任何破坏原始分布形态的异常值剔除或缩尾处理，仅进行无量纲化的标准化操作，从而在保障计算稳定性的同时，实现了对极端风险特征的无损保留。但该操作要求后续建模时使用对重尾分布具有稳定性的模型方法。值得注意的是，“Net Income Flag”一列方差为0，即为常数列，不含任何信息，故删去该特征。

为防止数据泄露导致影响模型训练效果，本文按照7:3划分训练集与验证集后，后续的模型训练与建立均基于训练集，仅在模型评估处使用验证集。

4.2 数据探索性分析

在正式建模前，先对数据集进行探索性分析。

对目标变量“是否破产”的分布进行可视化如下：

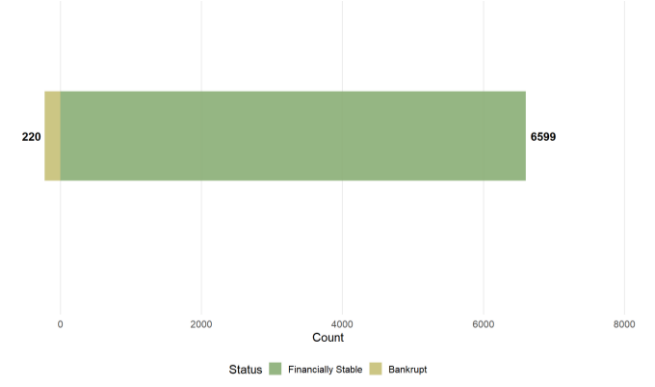


图1 类别横向堆积柱形图

如图所示，稳定企业的数量远远超过破产企业数量，说明该分类问题存在极度样本不平衡问题，这提示在后续的处理中引入惩罚机制来平衡正负样本。

接下来，本文探索目标变量与各个特征的相关性强弱。计算相关性时，连续特征与连续特征之间采用标准皮尔逊相关系数：

$$r=\frac{\sum(X_i-\bar{X})(Y_i-\bar{Y})}{\sqrt{\sum(X_i-\bar{X})^2\sum(Y_i-\bar{Y})^2}};\tag{1}$$

而连续特征与目标变量之间采用点二列相关系数：

$$r_{pb}=\frac{M_1-M_0}{S_n}\sqrt{\frac{n_1 n_0}{n^2}}\tag{2}$$

最终将结果可视化展示如下：

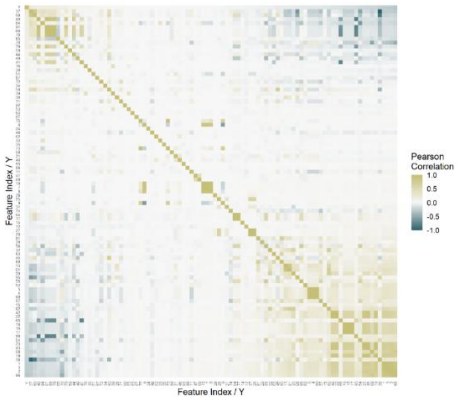


图2 全部特征相关性热力图

再取与目标变量相关性最强的 15 个特征绘制相关性热力图：

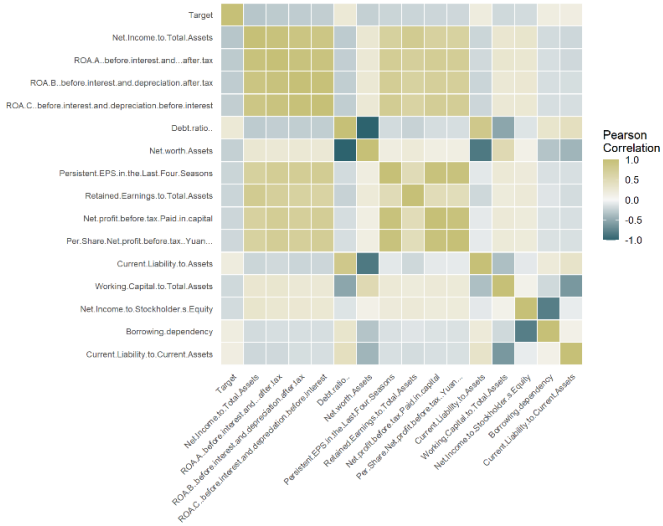


图3 相关性 Top15 特征与目标变量相关性热力图

如上两图所示，目标变量与各个特征之间相关性较弱，并且仅有部分特征与目标变量间存在较强相关性。此外，部分特征对目标变量有一致的影响，热力图呈现同色分块的现象。虽然该结果可能受异常值影响，**但依然能收获以下提示：**

(1) 特征与特征之间可能存在非线性关系；

(2) 单个特征对目标变量的单独影响较小，想要保持一定模型规模（特征数量）的同时有较好的模型效果，需要考虑交互项关系；

(3) 可以考虑对特征进行分类。

除此之外，本文还取相关性最强的前 15 个特征分析破产与不破产企业的特征分布如下：

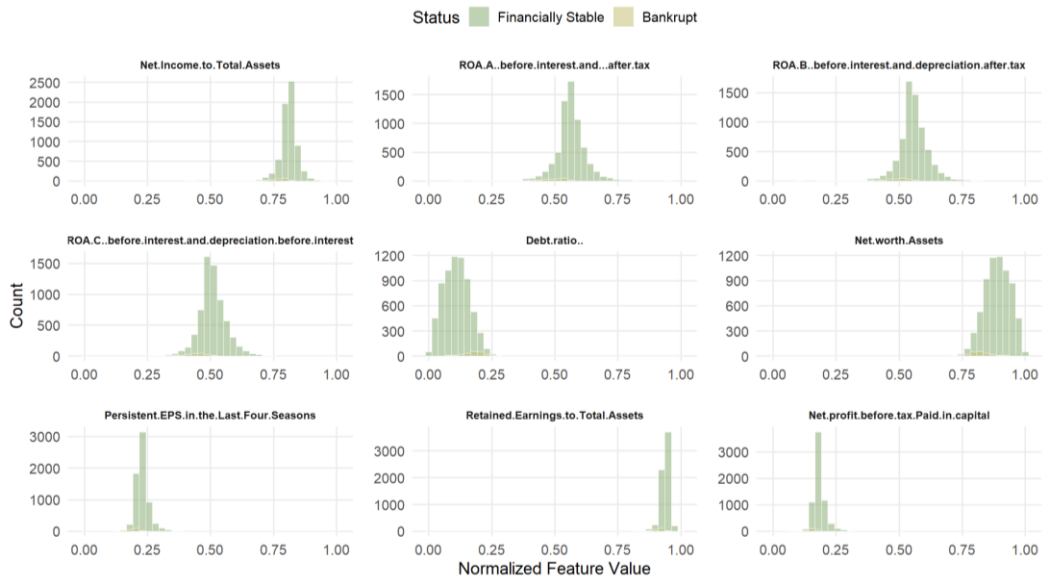


图4 相关性最强 15 个特征关于目标变量的类别条件分布图

可以很清楚地看到，破产与不破产企业之间的特征分布差异极大，破产企业的部分特征小的几乎看不见，而稳定企业的这些特征则是显著高于破产企业，这说明部分特征关于是否破产存在明显差异、部分特征对目标变量存在较明显的阈值效应。

五、 主要模型

5.1 模型建立

5.1.1 特征工程

Li 等人 2006 年的实证研究分析了 113 个实验设计，发现：当两个主效应都显著时，交互作用显著的概率为 33%；当只有一个主效应显著时，概率骤降至 4.5%；当两个主效应都不显著时，概率仅 0.48%[20]。事实上，在过去的关于交互项的研究中，多数学者基于**遗传性原则**采用两步法的方式，即先通过相关性或者建立 SCAD 模型保留部分与目标变量强相关的主效应，再基于这些受限效应考虑交互效应。又或者是直接针对高维特征

空间之间进行 LASSO 等惩罚项回归。虽然这二者均是严谨有效的方法，但是在经济学中，尤其是在极端的系统性金融风险中，通常存在大量的**纯交互效应**，例如，企业的轻微负债和短期现金流紧张作为单独的主效应，可能看起来健康，但两者一旦叠加就出现就有可能引发债务违约；又或者是经济特征的独特性要求进行多项式或样条展开导致特征数量超过 10000，形成超高维特征空间，导致 LASSO 等方法表现出现较大下滑。

鉴于财务指标常具显著的非线性阈值效应（如资产回报率分布的破产异质性），由下图也可以看出破产企业的利息和折旧前的总资产回报率基本均小于 0.5，而正常企业则是围绕在 0.5 附近在整个区间均有分布，暗示阈值效应的存在。故本文引入自然三次样条（Natural Cubic Splines, NCS）对特征进行基函数展开。较之传统多项式，NCS 通过施加边界线性约束，在保留内部节点高阶平滑性的同时，有效克服边界振荡，降低端点估计方差，显著提升模型的外推稳定性。此外，因“Liability.Assets.Flag”变量呈现极端分布致使节点重合，故不予样条展开。

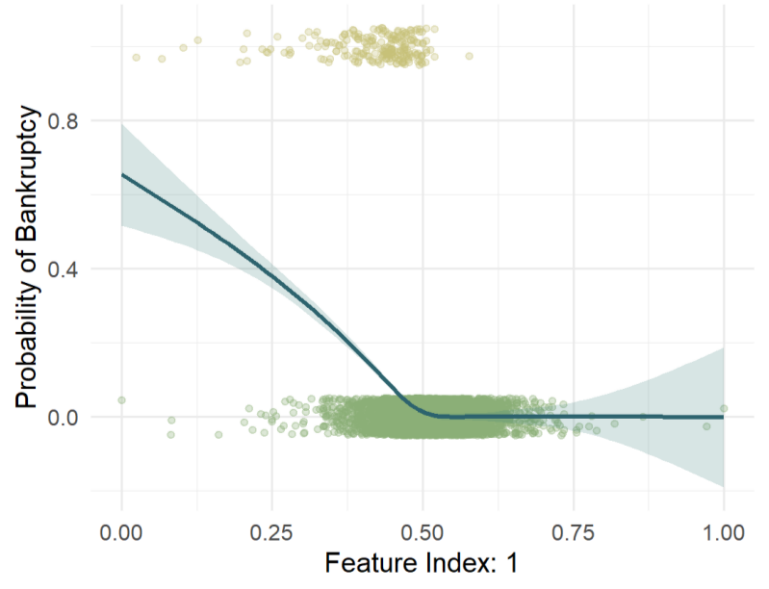


图5 Gam 平滑曲线图

但是，如果在此之后对所有特征进行两两交叉取交互项会导致维度爆炸，降低模型的精准度与求解难度，不仅如此，还会引入许多无实际经济含义的交互项。因此，本文借助大语言模型，结合**经典杜邦分析法**，将所有特征字段名上传给大语言模型并令其分类，最终得到下表五大类特征集合。

表2 特征分类表

类别	特征
盈利能力与收益质量	X1-X12、X15、X42、X43、X68、X69、X86、X89、X90
偿债能力与杠杆结构	X14、X35-X41、X60、X64、X66、X67、X77-X79、X84、X85、X91-93、X94
现金流与流动性	X13、X20、X32-X34、X54-X59、X61-X63、X65、X74、X75、X80-X83
营运能力与经营效率	X44-X53、X70-X73、X76、X87、X88
成长能力与每股绝对规模	X16-X19、X21-X31

注：具体字段名见 kaggle 网站，其中原数据集特征“Net Income Flag”已在上文中删去。

为验证分类的准确性，本文依照上文的相关性公式计算类别平均相关性系数矩阵，可视化展示如下：

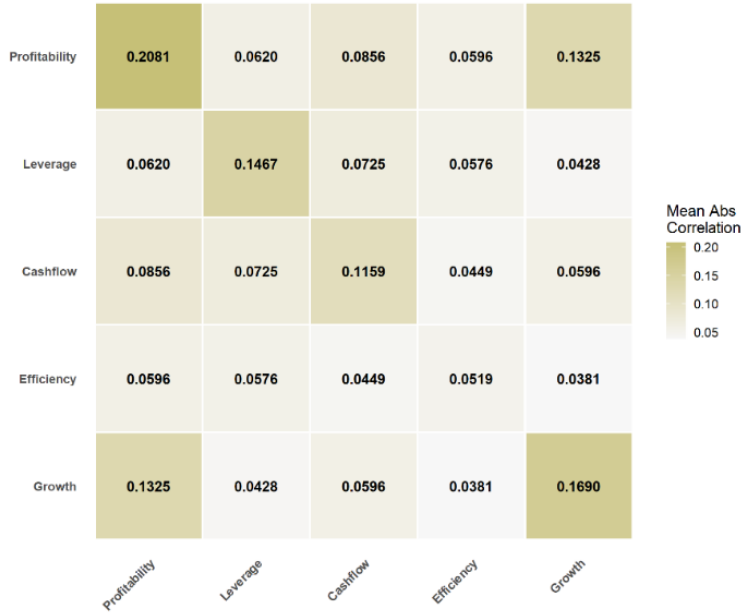


图6 类别平均相关性系数热力图

结果显示，整体特征分类效果良好，基本上均为类内平均相关性系数最大。对类内所有特征与目标变量进行相关性分析，结果可视化如下：

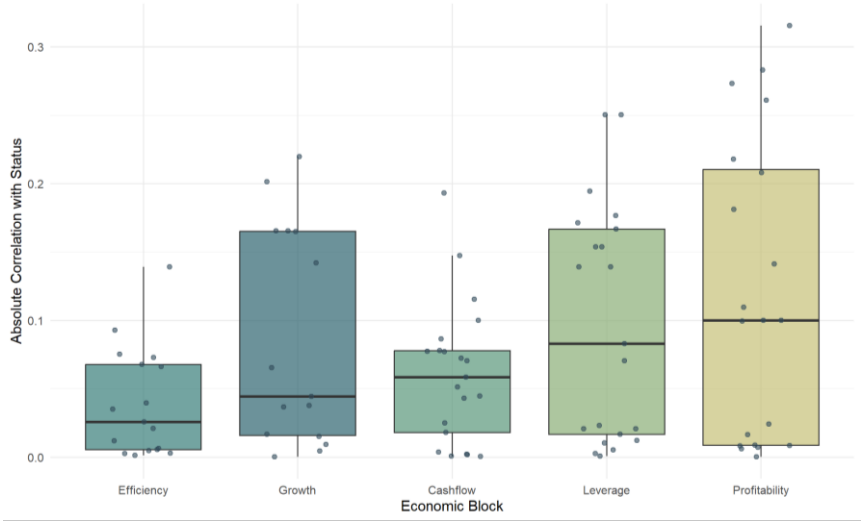


图7 各类内特征与目标变量相关性箱线图

可以看出，盈利能力与收益质量整体与目标变量相关性较强，并且与目标变量相关性最强的三个特征均属于该类。而营运能力与经营效率则整体与目标变量相关性较弱。

再取各个分区分别对目标变量建立逻辑回归模型，并计算 McFadden's Pseudo-R^2（$1-\frac{\ln L(\text{model})}{\ln L(\text{null})}$）。

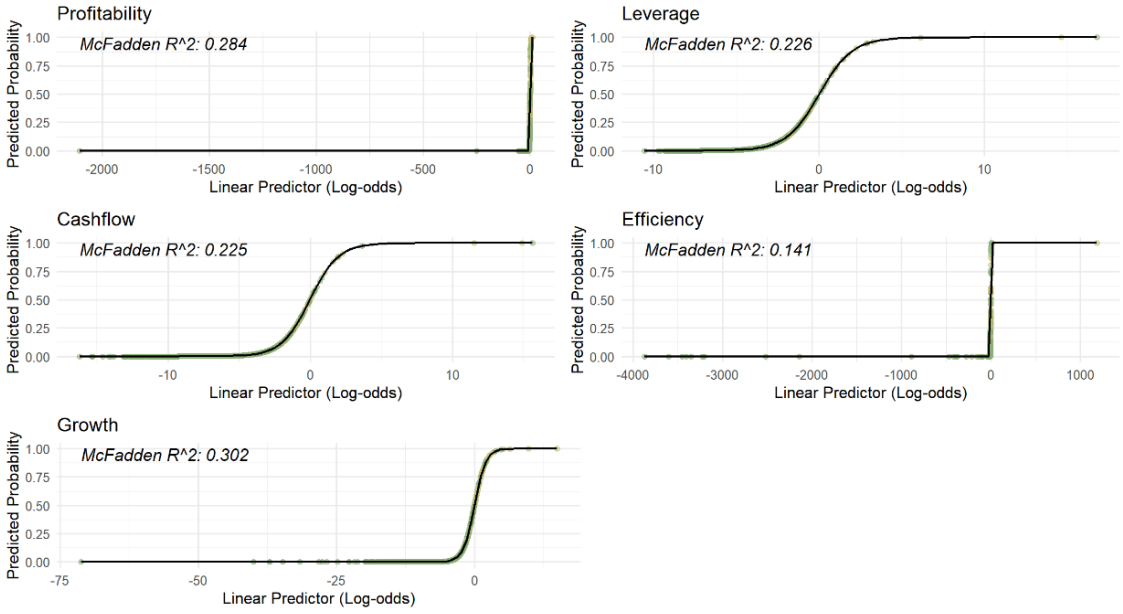


图8 逻辑回归拟合图

显然，不同类别之间存在明显差异。盈利能力与收益质量与营运能力与经营效率两类出现了极为明显的跃迁现象，暗示阈值效应的存在。此外，这两类对数几率被推到了-2000 甚至-4000，这说明模型参数估计实质上已经发散，R^2 不再可靠。特征与极度不平

衡的目标变量之间存在强烈的线性分离倾向，或者区块内部存在极强的多重共线性，传统的无惩罚逻辑回归或线性判别分析在该数据集上不适用。

最后，将五类特征集进行两两样条交叉，并加上主效应，新数据集特征数量为 4773×31616。在现代高维统计理论中，当 $p\gg n$ 且达到万维级别时，数据空间已呈现出典型的超高维特征[21]。若将该矩阵直接输入 SCAD 等惩罚回归模型，不仅面临极高的计算复杂度和共线性问题，更会因海量无关变量的干扰导致正则化算法收敛困难与估计失效。因此，在接入精确的惩罚模型之前，本文必须引入独立筛选（SIS）机制进行降维。

但是，使用上述升维框架有以下**三大痛点**亟需解决：

1. 未进行异常值处理，算法需要具有稳健性
2. 极大地增加了计算负担
3. 容易选出纯噪音的交叉项，即具有较高的假阳性率（False Discovery Rate，下记 FDR）

5.1.2 GCor-SIS-REDS-MDS 算法

首先，针对超高维特征筛选，Fan（2008）基于边际相关性提出确定性独立筛选（sure independence screening，下记 SIS）方法，并取得较好效果[21]。他提出，在条件 C_1 和条件 C_2 下：

$$\begin{cases} C_1:\min\limits_{j\in\mathcal{A}} h_j \geq 2c_1 n^{-\kappa}, c_1>0 \ and \ 0<\kappa<\dfrac{1}{2} \\ C_2:\log p = o\left(n^{1-2\kappa}\right) \end{cases}, \tag{3}$$

SIS 方法具有以下两个性质：

$$P\left(\max_{1\leq j\leq p}|\hat{h}_j - h_j| \geq c_1 n^{-\kappa}\right) \leq O(p\exp(-c_2 n^{1-2\kappa})) \tag{4}$$

$$P(\hat{\mathcal{A}}_n = \mathcal{A}) \xrightarrow{a.s.} 1, as \ n\to\infty \tag{5}$$

这两个性质保证了 SIS 方法具有确定筛选性，即当样本量最够大时能够找出有效变量。自此之后，多种基于不同边际相关性的 SIS 方法层出不穷，其中 Li 等（2012）基于距离相关性的 DC-SIS 方法广为流传。尽管各种 SIS 方法在不同场合大放异彩，但多数 SIS 方法并不能解决上述提到的两个痛点，如 BCor-SIS[22]、PC-SIS[23]虽然具有较强的筛选能力，但是均有较大的计算复杂度，并且无法解决假阳性问题。幸运的是，Jiang 等（2025）提出的 **Gcor-SIS-REDS** 方法能够解决上述三个痛点[24]。

Jiang 等（2025）引入 Grothendieck 相关性作为特征与目标变量间边际相关性的衡量指标，并对 FDR 进行严格的控制。具体算法如下：

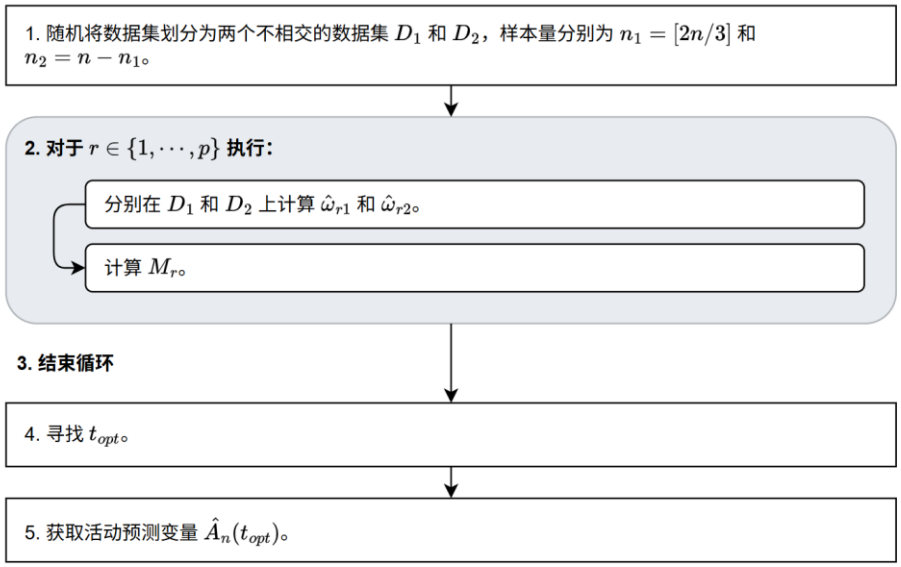


图9 GCor-SIS-REDS 算法流程图

其中，ω_r 计算如下：

$$\omega_r = GCor(X_r, Y) = \sqrt{GCov(X_r, Y)} \tag{6}$$

$$\begin{cases} A_{ij} = a_{ij} - \dfrac{1}{n-2}\sum\limits_{k\neq i} a_{ik} - \dfrac{1}{n-2}\sum\limits_{l\neq j} a_{lj} + \dfrac{1}{(n-1)(n-2)}\sum\limits_{k\neq l}\sum a_{lk}, \\ B_{ij} = b_{ij} - \dfrac{1}{n-2}\sum\limits_{k\neq i} b_{ik} - \dfrac{1}{n-2}\sum\limits_{l\neq j} b_{lj} + \dfrac{1}{(n-1)(n-2)}\sum\limits_{k\neq l}\sum b_{lk}, \\ a_{ij} = \kappa(\mathbf{X}_i, \mathbf{X}_j), \quad b_{ij} = \kappa(\mathbf{Y}_i, \mathbf{Y}_j). \end{cases} \tag{7}$$

$$GCov^2(\mathbf{X}, \mathbf{Y}) = \frac{1}{n(n-3)}\sum_{i\neq j} A_{ij}B_{ij} \tag{8}$$

M_r，t_{opt} 和 $\hat{A}_n(t_{opt})$ 计算如下公式：

$$M_r = \text{sign}(n_1\hat{\omega}_{r1} - n_2\hat{\omega}_{r2})(n_1\hat{\omega}_{r1} \vee n_2\hat{\omega}_{r2}), \tag{9}$$

$$t_{opt} = \inf\left\{t > 0 : \frac{1 + \sharp\{r : M_r \leq -t\}}{\sharp\{r : M_r \geq t\} \vee 1} \leq \alpha\right\}, \tag{10}$$

$$\hat{\mathcal{A}}_n(t) = \{r \in \{1, \cdots, p\} : M_r \geq t\}. \tag{11}$$

上述计算流程的复杂度为 $O((p+q)n^2)$，此处 $q=1$，显著优于 BCor-SIS（$O((p+q)n^2\ln n)$ 和 PC-SIS（$O((p+q)n^3)$。

Jiang 等还提出，在上述的 C1，C2 假定下，GCor-SIS-REDS 除了具备上述的两条定理外，还具有对重尾分布的稳健性以及如下性质：

$$\mathrm{FDR}=E\left[\frac{\sharp\{r:r\in\hat{\mathcal{A}}_n(t_{opt})\cap\mathcal{I}\}}{\sharp\{r:r\in\hat{\mathcal{A}}_n(t_{opt})\}\vee 1}\right]\leq\alpha+o(1), \tag{12}$$

当$n,p\to\infty$是有$o(1)\to 0$。**这说明当n,p足够大时 FDR 能够得到有效控制**。

然而，本文在实际操作中发现该方法会引入一个新问题，即该方法对 FDR 的硬约束与随机划分数据子集会导致结果的不稳健：在单次划分D_1和D_2时，单纯依赖一次样本分割会使结果对数据的微小扰动极其敏感，若极端杠杆点如果恰好不成比例地落入了样本量较小的D_2集中，算法会计算出极大的$\hat{\omega}_2$，进而导致M_r变成巨大的负数。

为解决该问题，本文引入了多重数据拆分 (Multiple Data Splitting，下记 MDS)来解决上述不稳健问题，并采用并行计算方式加快算法计算。Meinshausen 等（2010）提出，通过对数据进行多次子抽样或拆分，记录每个变量在B次惩罚回归中被选中的频率$\hat{\Pi}_r$，并只保留那些被选中频率$\hat{\Pi}_r>\tau$（通常取$\tau=0.5$）的变量，可以显著降低错误发现的数量，并且给出了有限样本下控制族系错误率和错误发现率的理论上界[25]。

5.1.3 平滑切片绝对偏度（Smoothly Clipped Absolute Deviation, SCAD）

SIS 算法筛选出的特征集通常仍会保留一定维度（对于不具备 FDR 控制的 SIS 算法通常取边际相关性最大的前$\left[\frac{n}{\ln(n)}\right]$个特征[21]。此处中括号表示向下取整），故通常对筛选后的特征进行二次筛选。

平滑切片绝对偏度（下记 SCAD）惩罚函数由 Fan 和 Li 于 2001 年提出，是一种非凸惩罚方法，旨在同时实现高维数据建模中的变量选择与参数估计[26]。相较于传统的 LASSO 惩罚，SCAD 能够有效克服由于对大系数过度惩罚而导致的估计有偏性，从而兼具连续性、稀疏性以及无偏性这三大优良特性，即在理论上具备 Oracle Property（神谕性质）。在统计建模应用中，SCAD 通过在对数似然或损失函数中引入特定的惩罚项来实现特征的自动筛选，其核心的惩罚函数解析式定义为如下的分段函数：

$$p_\lambda(|\beta|)=\begin{cases}\lambda|\beta|, & |\beta|\leq\lambda\\ \dfrac{2a\lambda|\beta|-\beta^2-\lambda^2}{2(a-1)}, & \lambda<|\beta|\leq a\lambda\\ \dfrac{\lambda^2(a+1)}{2}, & |\beta|>a\lambda\end{cases} \tag{13}$$

上式中，β代表模型待估参数，λ为大于零的调节参数，用于控制整体惩罚力度；a为控制惩罚率衰减的超参数，理论推导要求$a>2$。在经验研究与实际计算中，基于最小化贝叶斯风险的考量，通常采纳原作者的建议将超参数a设定为 3.7。由于该惩罚函数在部分区间非凸且在原点不可导，实际求解模型时通常需要借助局部线性近似或局部二次近似等数值优化算法将其转化为易于处理的凸优化问题进行迭代求解。事实上，基于该数据集二分类场景建立的 SCAD 模型相当于逻辑回归加上 SCAD 惩罚项。

对于目标函数：

$$\min_{\beta}\left\{-\frac{1}{n}\sum_{i=1}^{n}w_i[y_i(X_i^T\beta)-\log(1+\exp(X_i^T\beta))]+\sum_{j=1}^{p}p_\lambda(|\beta_j|)\right\} \tag{14}$$

本文取少数类的权重$\omega=\frac{\sharp\{Y=0\}}{\sharp\{Y=1\}}\approx 32$，这迫使模型在优化迭代时，对少数类错分的惩罚力度与多数类的整体惩罚力度等同，从而纠正了标准逻辑回归倾向于将样本预测为多数类的先验偏倚。相比于采用过采样或欠采样解决样本不平衡问题，该方法不会改变原始数据的联合分布特征空间，使得结果更加准确。

根据最小化上述目标函数，能够估计出特征参数。最终模型结构如下式所示，其中p指企业发生破产的概率：

$$\log\left(\frac{p}{1-p}\right)=\beta_0+\beta_1X_1+...+\beta_pX_p \tag{15}$$

5.2 模型求解

针对 GCor-SIS-REDS-MDS，本文根据 Jiang 等的论文使用 R 语言复现 GCor-SIS-REDS 并加入 MDS 逻辑，设置 FDR 阈值$\alpha=0.1$，重复次数$B=20$以及频率规则$f>0.7$。最终 GCor-SIS-REDS-MDS 筛选出了 5218 个特征，使得数据集由超高维数据下降到低维数据，符合 Fan 和 Lv 提出的下降后的维度在$\left[\frac{n}{\ln(n)}\right]$内[21]。筛选出来的特征在 20 次独立分割中被筛选出来的频率可视化如下：

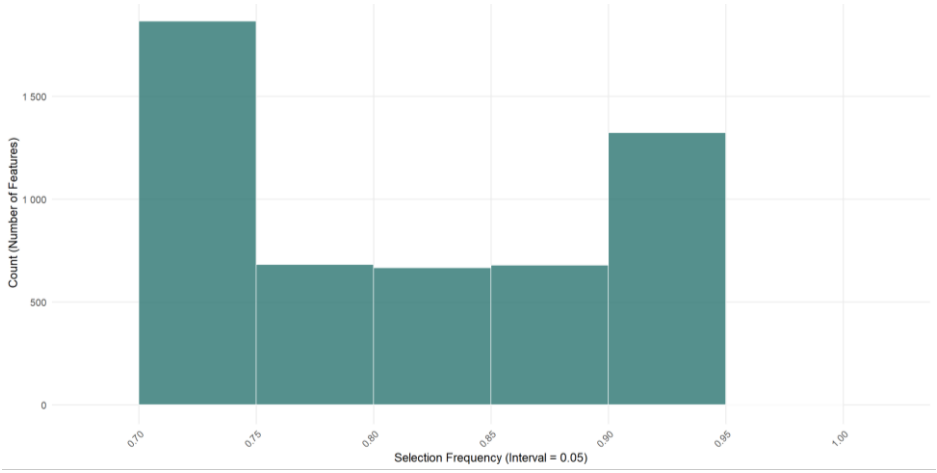


图10 特征筛选频率直方图

可以看到多数特征被选出的频率处于(0.70, 0.75]以及(0.90,0.95]两个区间内。值得注意的是，没有一个特征被选出的概率是 100%，反映有效特征的边际得分在不同子样本中必然产生波动，导致其在少数迭代中跌出 SIS 的硬截断边界，说明本文进行 MDS 是合理且必要的。

之后，在 150 个λ构成的网格路径上进行了 10 折交叉验证训练 SCAD 模型，惩罚项的形状参数γ（即上文提到的α）设定为 3.7，类别权重详见上文。

最终 SCAD 选出了 16 个有效特征，可视化结果如下：

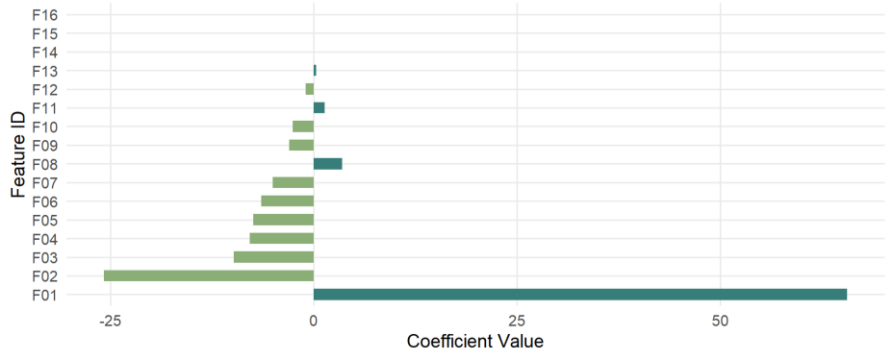


图11 最终有效特征及其系数条形图（特征名称映射详见下表）

在完成 SIS 降维与 SCAD 自适应惩罚收缩后，模型从上万维的特征中锁定了如上图所示的有效特征。在最终幸存的非零系数特征中，交互项占据了主导地位，且多聚焦于样条函数的非线性突变区 ns2、ns3。这一结果从统计底层证实了企业破产并非单一维度的线性衰退，而是多重财务恶化在特定阈值下的非线性共振。此外，符合预期的是，

交叉项全部包含了杠杆分区，**显示出负债是引爆风险的核心枢纽**。当高杠杆与盈利下滑、效率降低或现金流枯竭发生非线性交叉时，系统性违约风险会被迅速放大。

表3 特征名称映射表

ID	模块	变量 A	变量 B
F16	杠杆×效率	X78 - Current Liability to Equity (ns1)	X50 - Net Worth Turnover Rate (times) (ns1)
F15	杠杆×成长	X92 - Degree of Financial Leverage (DFL) (ns1)	X30 - Net Value Growth Rate (ns2)
F14	无交叉(线性)	X90 - Net Income to Stockholder's Equity (原始线性项)	无
F13	杠杆×效率	X40 - Borrowing dependency (ns1)	X47 - Average Collection Days (ns2)
F12	盈利×现金流	X86 - Net Income to Total Assets (ns1)	X57 - Cash/Total Assets (ns2)
F11	盈利×杠杆	X90 - Net Income to Stockholder's Equity (ns1)	X39 - Long-term fund suitability ratio (A) (ns3)
F10	杠杆×效率	X40 - Borrowing dependency (ns1)	X47 - Average Collection Days (ns3)
F09	杠杆×成长	X36 - Total debt/Total net worth (ns2)	X19 - Persistent EPS in the Last Four Seasons (ns1)
F08	盈利×效率	X9 - Non-industry income and expenditure/revenue (ns2)	X52 - Operating profit per person (ns2)
F07	杠杆×效率	X40 - Borrowing dependency (ns1)	X47 - Average Collection Days (ns1)
F06	杠杆×成长	X92 - Degree of Financial Leverage (DFL) (ns1)	X30 - Net Value Growth Rate (ns1)
F05	杠杆×效率	X66 - Current Liabilities/Equity (ns1)	X50 - Net Worth Turnover Rate (times) (ns1)
F04	杠杆×现金流	X38 - Net worth/Assets (ns2)	X34 - Quick Ratio (ns2)
F03	杠杆×成长	X40 - Borrowing dependency (ns2)	X31 - Total Asset Return Growth Rate Ratio (ns2)
F02	杠杆×效率	X66 - Current Liabilities/Equity (ns1)	X46 - Accounts Receivable Turnover (ns2)
F01	盈利×杠杆	X86 - Net Income to Total Assets (ns2)	X38 - Net worth/Assets (ns2)

相比于热门机器学习或深度学习架构，该模型一大优点为较强的可推导性以及经济可解释性。

首先，本文进行了显著性检验并计算量置信区间。针对 SCAD 惩罚导致传统检验的失真，本文采用重拟合策略进行后选择推断，基于其筛选的非零变量子集**重构 Logistic**

回归。为规避高维稀疏特征诱发的完全分离问题，本文构建两轮诊断机制：于初始拟合中剔除共线性别名化及标准误发散（大于 10）的不可靠变量，继而在精简集上执行二次拟合以保障参数稳定性。此外，为修正有限样本下渐近正态假定的偏差，引入**非参数 Bootstrap 重抽样**（B＝200 次）计算百分位置信区间，作为 Wald 区间的重要对照；若极端重抽样子样本因分离致使极大似然估计失效，则自适应降级为 **Firth 惩罚似然**以确保算法收敛。在 0.05 显著性水平下，剔除 F07、F10、F12、F15 及 F16 五个变量后，最终检验结果如下表所示。

表4 后选择推断结果表

变量	系数	标准误	p 值	95% CI (Wald)	Bootstrap CI
截距	5.97	2.48	0.016	[1.11, 10.83]	[-8.70, 26.36]
F01	58.29	2.46	<0.001	[53.47, 63.11]	[40.11, 79.72]
F02	-42.68	3.34	<0.001	[−49.23, −36.13]	[−72.58, −27.50]
F03	-42.37	5.71	<0.001	[−53.56, −31.18]	[−95.06, −20.06]
F04	-4.35	0.62	<0.001	[−5.57, −3.13]	[−8.60, 0.21]
F05	-60.71	6.58	<0.001	[−73.61, −47.81]	[−127.59, −15.10]
F06	-3	2.06	0.146	[−7.04, 1.04]	[−10.11, 24.44]
F08	5.38	2.69	0.045	[0.11, 10.65]	[−6.76, 26.00]
F09	-20.71	1.08	<0.001	[−22.83, −18.59]	[−33.20, −14.57]
F11	2.26	1.64	0.17	[−0.95, 5.47]	[−21.65, 9.75]
F13	-2.86	0.31	<0.001	[−3.47, −2.25]	[−5.84, −0.39]
F14	-0.15	0.08	0.054	[−0.31, 0.01]	[−0.70, 0.46]

由上表，仅有三个特征不显著。作为全场系数绝对值最大的特征，F01（净资产收益率 ns2×净资产比率 ns2）构成了模型中最主要的预测贡献，反映了模型对净资产收益率与净资产/资产的共同适中状态表现出极高的敏感度：这**两者均处于中等规模下时反而会推动企业破产**。推测可能是两指标均处于中等规模下的企业通常缺乏竞争优势且面临决策迷失。一方面，它们缺乏高抗风险性和高成长性，无法通过丰厚的利润留存应对突发危机；另一方面，它们虽然没有极端的债务危机，但也承担着常规的利息负担。在经济下行期或行业出清阶段，这类平庸的企业可能更容易因资金链断裂而破产，即当企业资产创利能力恶化，且自有资本缓冲垫薄弱时，破产风险呈非线性放大。这一方向与

Altman（1968）的 Z-Score 框架中 Retained Earnings/Total Assets 和 EBIT/Total Assets 的核心逻辑一致：盈利积累与资本结构共同决定企业生存能力[6]。特别值得注意的是 F14（净利润与股东权益比率）作为唯一幸存的纯线性项虽然通过了 SCAD 惩罚，但是影响并不显著。F05（流动负债/权益 ns1 × 净值周转率 ns2）效应量为负且绝对值最大的特征，反映在短期债务压力高企的背景下，若权益周转率处于中等水平，破产风险仍会显著上升。印证了 Ohlson（1980）关于短期流动性与营运效率交互影响企业存续的判断[7]。其他特征因篇幅原因不在此继续展开讨论。可以看到，显著变量中有 7 项涉及杠杆维度与其他维度的交叉，表明杠杆水平在放大或缓冲其他维度风险中发挥着核心角色。

上表还展现出 Bootstrap 置信区间的平均宽度为 Wald 置信区间的 3.94 倍，两者存在系统性偏差。这一系统性偏差的根源在于本文数据固有的结构性共线性。本文的特征工程本质上是在创造高维交互特征空间。这一扩展在提升预测精度的同时，也引入了变量间的高度相关性。在此条件下，Logistic 回归的 Fisher 信息矩阵趋于病态，其逆矩阵低估了真实的抽样变异。Bootstrap 方法通过对原始数据的重复抽样，无需依赖信息矩阵的可逆性假设，因而能够更加真实地反映参数估计的不确定性。

最终 Bootstrap 置信区间可视化展示如下图。

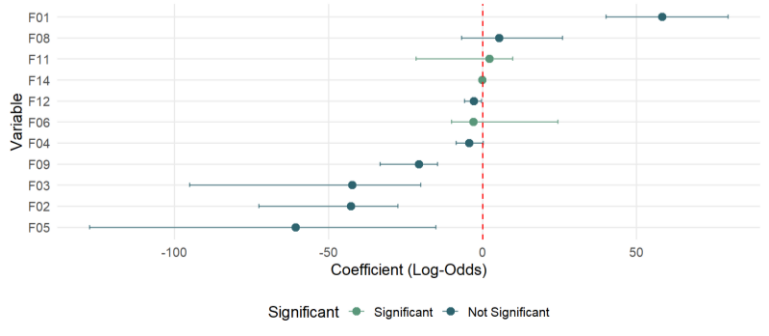


图12 Bootstrap 后选择推断可视化结果图

通过最大化 Youden 指数（$TPR + FPR - 1$）寻优得到的最佳截断阈值为 0.0317。0.0317 并非企业真实的违约概率，而是相对风险经验分位数。该数值在统计上表征了模型区分正负样本的最佳决策边界：即当企业的相对风险评分越过 0.0317 这一拐点时，模型将其判定为高危群体能够最大化统计层面的敏感度与特异度之和。

接下来，进行代价敏感转移分析如下。不妨假设破产的预期误判成本为$(1-p)\cdot C_{FP}$，健康的预期的误判成本为$p\cdot C_{FN}$，根据**贝叶斯决策理论**，当预测为破产的期望成本小于预测为健康的期望成本时，才能将其标记为可能破产，即当：

$$(1-p)C_{FP} < pC_{FN} \tag{16}$$

其中p为最优阈值。解该不等式得理论最优阈值：

$$p^* = \frac{C_{FP}}{C_{FN}+C_{FP}} = \frac{1}{1+\frac{C_{FN}}{C_{FP}}} \tag{17}$$

假设所求最优阈值（求解为 0.0317）即为理论最优阈值，此时带入上式得到：

$$0.0317 = \frac{1}{1+\frac{C_{FN}}{C_{FP}}} \Longrightarrow \frac{C_{FN}}{C_{FP}} \approx 30.5 \tag{18}$$

这说明漏掉一个破产企业的代价，大约是错杀一个健康企业代价的 30.5 倍，再次从数据端论证了找出破产企业的重要性。

接下来，对最终模型进行评估，可视化结果如下：

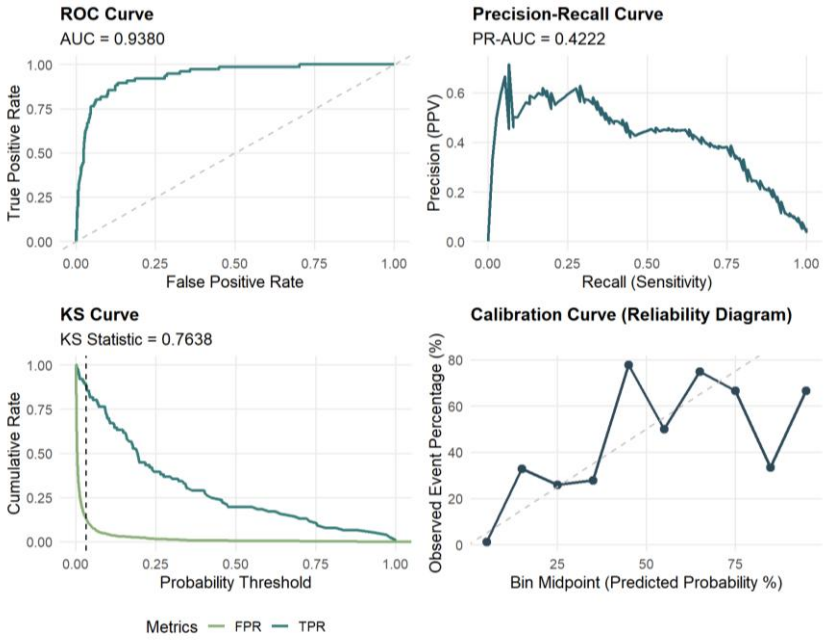


图13 主模型评估组合图

由上图可以看出，AUC 被乐观估计为 0.9380，而 PR-AUC 仅为 0.4222，说明为了捕获更多的阳性样本，模型不可避免地引入了大量假阳性，导致预测精确率迅速下滑。KS 统计量为 0.7638 表明模型对正负样本的分布有极强的分离能力，模型挑选出破产企业的能力相当出色。可靠性图表显示模型输出的概率与实际观测到的频率存在一定偏离，这很可能是因为建模时引入了权重导致的。具体各个模型指标（F1 分数等）详见下文模型比较部分。总而言之，该模型大体拥有较好的分类性能。

为进一步进行经济分析，本文通过后验概率反向校准进行概率修正：

$$p_{true}=\frac{p_{weighted}}{p_{weighted}+32\times(1-p_{weighted})} \tag{19}$$

其中，$p_{weighted}$为模型估计的特征参数经 Sigmod 函数还原后得到的。

基于上述修正，我们再得到各个企业的修正概率后，通过与阈值 $p^*=\frac{C_{FP}}{C_{FN}+C_{FP}}=\frac{1}{1+\frac{C_{FN}}{C_{FP}}}$ 进行比较，实现根据不同的经济学条件，输出银行是否对企业进行贷款的最优决策：

1. 若利息$r=5\%$，违约损失率$LGD=100\%$（即无抵押）时，此时$C_{FP}=r, C_{FN}=LGD$，模型规定当企业的真实破产概率低于 4.76%时（根据上述阈值公式计算得到），进行放贷。其结果是筛选出 2025 家企业，其中 63 家破产，最终银行的净利润为 3510 万元。

2. 若利息$r=6\%$，违约损失率$LGD=40\%$（能收回 40%的贷款）时，此时$C_{FP}=r, C_{FN}=LGD$，模型规定哪怕当企业的真实破产概率达到了 13.04%时（根据上述阈值公式计算得到），也进行放贷。其结果对于同样的验证集是筛选出 2035 家企业，其中 71 家发生破产，最终净利润达到 8944 万元。

事实上，在 SCAD 模型权重比使用正负样本数量比例的前提下，上述修正所得到的结果与进行 King & Zeng 提出的截距修正（$p_{kz}=\frac{1}{1+\exp(-(\beta_0-\ln(\omega)+X\beta))}$）[27]所得到的结果完全一致，前者是从概率层面（利用贝叶斯后验比例）进行反向推导，后者从从参数层面（在对数发生比尺度上调整截距）进行前向推导。具体的理论证明在此处不进行。

上述决策可视化如下：

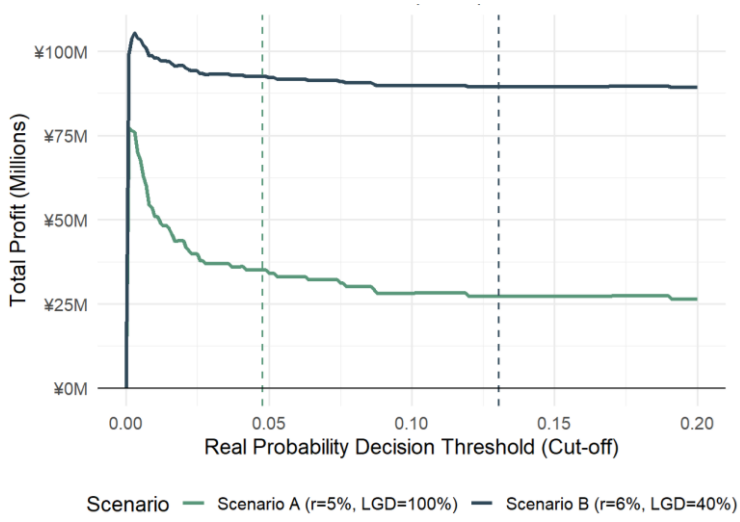


图14 各情况下最优决策示意图

上图表明，本模型能够迅速识别优质低风险客户，并在极低阈值区间实现利润的快速最大化。值得注意的是，经验利润曲线的峰值并未与理论最优阈值$p^* = \frac{r}{r + LGD}$重合，而是显著左偏。这一统计现象揭示了在处理极度不平衡的数据集时，模型存在一定程度上的局部失真。

六、 次要模型

6.1 模型建立

鉴于本研究数据集兼具高维、复杂非线性及显著的样本不平衡特征，本质属于非对称成本的二分类问题，传统线性模型难以有效捕捉其特征映射。为此，本文引入轻量级梯度提升机（LightGBM）构建破产预警模型。凭借直方图算法、单边梯度采样（GOSS）及互斥特征捆绑（EFB）等核心机制，LightGBM 在保障预测精度的同时，大幅优化了计算复杂度与内存消耗。

针对破产预测场景，LightGBM 展现出极高的技术契合度：第一，对不平衡样本的强鲁棒性。GOSS 机制在计算信息增益时聚焦大梯度样本并对小梯度样本随机采样，使模型在维持多数类整体分布先验的前提下，精准锚定破产企业特征，有效避免了 SMOTE 等重采样技术诱发的先验概率失真。第二，高效的高维特征处理能力。EFB 技术通过捆绑互斥特征实现无损降维，配合直方图算法将连续特征离散化，极大降低了最优分割点

的搜索成本。第三，灵活的类别特征直通机制。框架支持直接切分原始类别特征，规避了独热编码导致的数据稀疏化，最大程度保留了原始统计特性。

在模型训练阶段，鉴于本研究为二分类任务，模型采用二元交叉熵作为损失函数：

$$L = -\frac{1}{N}\sum_{i=1}^{N}[y_i \log(p_i) + (1-y_i)\log(1-p_i)] \tag{20}$$

其中，y_i为企业真实状态标签，p_i为模型预测企业破产的概率。同时，考虑到数据的不平衡性，本研究在模型参数中引入了类别权重惩罚（调整 scale_pos_weight 参数为负样本数量/正样本数量），进一步提升模型对破产样本的召回能力。

6.2 模型求解与评估

本文采用 R 代码进行训练并求解该模型。为应对样本不平衡问题，该模型设置与 SCAD 模型相同的权重参数，其他超参数详见附录代码。

最终模型选出了 91 个有效特征，SHAP 蜂窝图如下所示：

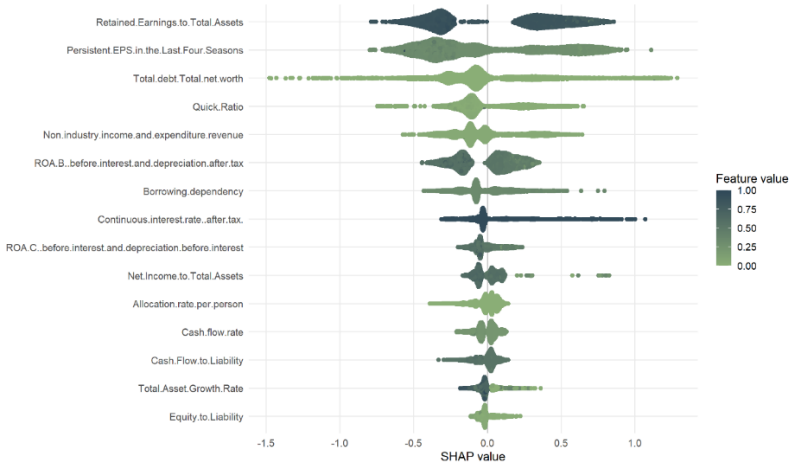


图15 SHAP 蜂窝图

可以看到，**留存收益占总资产的比例是重要性最大的特征**。从蜂窝图上可以看出有大量代表高留存收益比的深色点分布在 SHAP 为负的区域（代表降低破产风险），符合经济学常识；一部分点位于右侧并且与左侧点间有明显空白，暗示该特征存在阈值效应或与其他特征间存在交互效应。值得留意的是，多数特征如第二第三重要的特征（过去四季连续每股收益与总负债/总净值）的点颜色几乎相同地分布在左右两端，且左端相对较多，还存在部分立群的异常值点，说明这两个特征整体上起到降低破产风险的作用，

但是同时存在各种导致破产的交互作用，难以直接解释。同时，上图还能看出总资产增长率越高的企业破产风险越高，反之风险越低，符合经济学逻辑。

对该模型进行评估，可视化结果如下：

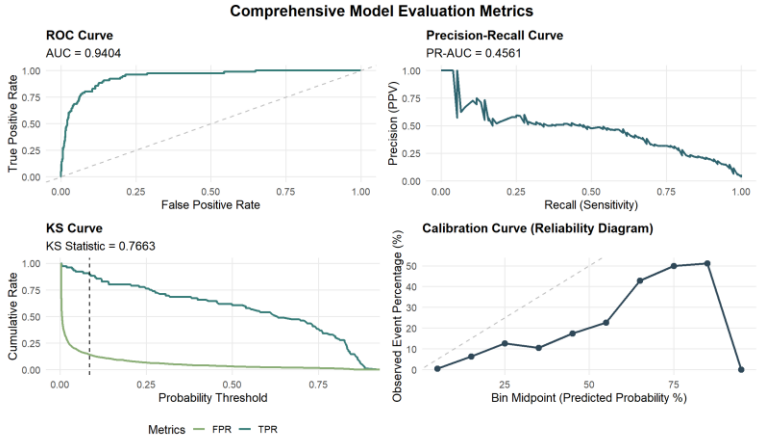


图16 LightGBM 模型评估组合图

不平衡样本导致 AUC 被高估表现出极高的数值，PR-AUC 为 0.4561 说明模型在试图捕捉正样本时，不可避免地带入了大量的假阳性。KS 统计量为 0.7663 说明模型对正负样本的区分能力极强。从可靠性图上看，由于设置了样本权重导致模型输出的绝对概率值远高于自然状态下的真实基础概率，存在明显的概率偏差。总体而言，该模型能够精准抓出破产企业，具有较良好的模型表现。

七、 模型评估与对比

接下来，我们对两个模型以及对原始数据进行拟合的逻辑回归模型的评估参数进行横向对比，如下表所示。

表5 模型评估参数对比表

指标	SIS+SCAD（样条交叉）	LightGBM	逻辑回归 (SMOTE)
ROC-AUC	0.938	0.9404	0.8207
PR-AUC	0.4222	0.4561	0.2246
KS Statistic	**0.7638**	**0.7663**	**0.6415**
Optimal Threshold	0.0317	0.0843	0.5
Precision (PPV)	0.2086	0.1983	0.2842
Recall (Sensitivity)	**0.8947**	**0.9079**	**0.7105**
F1-Score	0.3383	0.3255	0.406
F2-Score	**0.5397**	**0.5291**	**0.5466**

结果表明，双模型在破产预测效能上均显著优于传统的SMOTE-Logistic回归基准，并有效规避了后者在处理高维阈值与交互效应时面临的维度灾难与收敛失效问题。

就预测效能而言，LightGBM 在 AUC、KS 统计量及召回率上表现更佳，展现出极强的正负样本区分能力；而主模型则更优地权衡了召回与精确率，取得更高的 Precision、F1 及 F2 分数。就理论性质与解释性而言，区别于 LightGBM 黑盒非参数特性（缺乏全局线性系数与连续性），主模型具备双重优势：其一，依托 SCAD 惩罚，模型兼具无偏性、连续性与稀疏性等优良数学性质，支持严格的统计推断；其二，建立在样条交叉特征空间上的主模型，突破了 LightGBM 仅能隐式挖掘交互关系的局限，能够显式量化高阶交互效应与特征阈值影响，从而赋予各风险驱动因素以精确的经济学解释。

深入对比本文的主模型与 LightGBM 模型，可以发现二者分别映射了随机森林算法的奠基人 Breiman (2001)提出的“数据建模”与“算法建模”两种核心统计文化[28]。主模型遵循数据建模范式，假定企业破产状态由特定的随机数据生成机制决定，强调模型对经济变量的解释力；相反，LightGBM 模型作为算法建模的典型代表，将破产机制视为黑盒，以最优化预测性能为导向。正如 Breiman 所指出的，尽管算法模型在预测精度上表现卓越，本研究中 LightGBM 的高效与精准亦证实了此点，但在经济管理领域，数据模型所提供的可解释性具有不可替代的价值。本文的核心贡献之一在于，所提出的主模型不仅维持了严密的机制解释能力，且其预测准确率与 LightGBM 模型高度相当。这一结果表明，该模型成功融合了两种统计文化的优势，在兼顾经济学解释与预测效能方面展现出显著的优越性。

综上，在模型评估结果相近的前提下，主要模型具有更强的数学与统计推断性质、经济学可解释性、对特征阈值以及交互项的分析能力。从模型的可解释性角度，我们可以说，本文提出的模型在该问题上优于 LightBGM 模型。

八、 主要模型的评价与推广

8.1 模型的优点

(1) 模型充分结合实际，考虑了交互项与特征阈值影响，并针对超高维数据创新性地引入 GCor-SIS-REDS-MDS 算法，兼顾良好的模型预测效果的同时具有较强的经济可解释性。

(2) GCor 能够捕获多种非线性关系，并具有较强的稳健性。

(3) 引入大语言模型对特征进行快速准确的分类，简化了后续特征交叉的规模，强化了模型经济可解释性。

(4) 考虑了计算复杂度，并且模型无需进行复杂的调参工作。

(5) 模型的每一步建立均有据可循，相比黑盒模型，该统计模型具有更强的可解释性。

8.2 模型的不足

(6) 为增加创意，使用了 LLM 依据经济学原理对特征进行分类，缺乏数据与严谨的理论支撑，可以考虑使用层次聚类法进行替代。

(7) 样条展开的次数没有进行客观的分析与选择，而是采用了主观经验规则进行展开。

(8) 样条展开极大降低了模型的可解释性，对于阈值效应的分析有待未来找到更合适的代替。

8.3 模型的推广

可推广至任意 0-1 分类的经济学或其他需要模型可解释性的实际问题，如某种商品是否畅销等。此外，GCor-SIS-REDS-MDS 算法框架天然适用于超高维数据集，可与当前互联网经济现象紧密结合，可用于探索诸如网店倒闭原因探索等互联网时代下的全新经济学课题。

九、 结论

本文为探讨经济学特征阈值以及经济学交互项对企业是否破产的影响，对 Jiang 等人提出的算法[24]实用性改造提出了 GCor-SIS-REDS-MDS 算法，创新性地对经济学特征进行分区与样条交叉并将上述算法以及 SCAD 应用其中。最终模型分类效果接近 LightBGM 模型，并具有更强的数学与统计推断性质、经济学可解释性、对特征阈值以及交互项的分析能力。该模型为完全的白盒模型，因此能通过巴塞尔协议 IRB 法，进行金融风控。

根据模型结果，本文得到净资产收益率与净资产比率于共同适中状态更能推动企业面临更高的违约风险，并且负债的作用及其关键。主模型最终筛选出 16 个有效特征，其中 8 个特征通过了显著性检验。本文还分析得出漏掉一个破产企业的代价是错杀一个健康企业代价的 30.5 倍。此外，本文还依据主要模型建立了银行放贷决策器，实现针对不同利息与违约损失率，根据多个企业的多种经济学特征决定是否放贷以及对于期望最大收益。事实上，基于本模型优异的统计推断性质，还能够对阈值效应进行详细分析并协助制订监管红线等操作。

总而言之，本文提出的模型在该领域具有极好的综合表现。

十、 致谢

本论文的顺利完成，离不开各方的支持与帮助。首先，诚挚感谢大赛组委会提供的竞技与交流平台。其次，感谢本校及学院为本研究提供的学术资源与坚实后盾，以及各位专业教师在日常学习中的授业解惑。特别鸣谢导师在先前的科研过程中给予的悉心指导，以及课题组在底层算力方面提供的硬件保障。

参考文献

[1] 国务院. 2025年政府工作报告[R]. 北京: 人民出版社, 2025-03-05.

[2] 国务院.关于开展营商环境创新试点工作的意见: 国发〔2021〕24号[A/OL]. 2021-10-31

[3] 国家发展和改革委员会, 最高人民法院, 财政部, 人力资源和社会保障部, 自然资源部, 住房和城乡建设部, 中国人民银行, 国务院国有资产监督管理委员会, 海关总署, 国家税务总局, 国家市场监督管理总局, 中国银行保险监督管理委员会, 国家外汇管理局. 关于推动和保障管理人在破产程序中依法履职 进一步优化营商环境的意见: 发改财金规〔2021〕274号[A/OL]. 2021-02-26

[4] 中国共产党第二十届中央委员会. 中共中央关于进一步全面深化改革、推进中国式现代化的决定[R]. 北京: 人民出版社, 2024-07-18.

[5] Beaver W H. Financial Ratios as Predictors of Failure[J]. Journal of Accounting Research (Wiley-Blackwell), 1966, 4(3).

[6] Altman E I. FINANCIAL RATIOS, DISCRIMINANT ANALYSIS AND THE PREDICTION OF CORPORATE BANKRUPTCY[J]. The Journal of Finance, 1968, 23(4): 589-609.

[7] Ohlson J A. Financial Ratios and the Probabilistic Prediction of Bankruptcy[J]. Journal of Accounting Research, 1980, 18(1): 109.

[8] Grice J S, Dugan M T. RE-ESTIMATIONS OF THE ZMIJEWSKI AND OHLSON BANKRUPTCY PREDICTION MODELS[J]. Advances in Accounting, 2003, 2077-93.

[9] Tibshirani R. Regression shrinkage and selection via the lasso[J]. Journal of the Royal Statistical Society, Series B, 1996, 58(1).

[10] Hoerl A E, Kennard R W. Ridge regression: biased estimation for nonorthogonal problems[J]. Technometrics A Journal of Stats for the Physical Chemical & Engineering ences, 2000, 42.

[11] Zhang C H. Nearly unbiased variable selection under minimax concave penalty[J]. Annals of Statistics, 2010, 38(2): 894-942.

[12] Tian S, Yu Y, Guo H. Variable selection and corporate bankruptcy forecasts[J]. Journal of Banking & Finance, 2015, 5289-100.

[13] 杨青龙，田晓春，胡佩媛. 基于LASSO方法的企业财务困境预测[J]. 统计与决策, 2016, (23): 170-173.

[14] Liang D, Lu C, Tsai C, et al. Financial ratios and corporate governance indicators in bankruptcy prediction: A comprehensive study[J]. European Journal of Operational Research, 2016, 252(2): 561-572.

[15] 刘玉敏，申李莹，任广乾. 基于PCA-PSO-SVM的上市公司财务危机预警[J]. 管理现代化, 2017, 37(03): 12-14.

[16] 杨子晖，张平淼，林师涵. 系统性风险与企业财务危机预警——基于前沿机器学习的新视角[J]. 金融研究, 2022, (08): 152-170.

[17] 孟庆. 基于BP神经网络的农业类上市公司财务危机预警研究[D]. 福建农林大学, 2024.

[18] 朱应可. 基于可解释机器学习的上市公司财务危机预警研究[D]. 三峡大学, 2023.

[19] Qiu W, Rudkin S, Dłotko P. Refining understanding of corporate failure through a topological data analysis mapping of Altman’s Z-score model[J]. Expert Systems with Applications, 2020, 156113475.

[20] Chen K, Li W, Wang S. An Easy-to-Implement Hierarchical Standardization for Variable Selection under Strong Heredity Constraint.[J]. Journal of statistical theory and practice, 2020, 14(3).

[21] Fan J, Lv J. Sure Independence Screening for Ultrahigh Dimensional Feature Space[J]. Journal of the Royal Statistical Society. Series B (Statistical Methodology), 2008, 70(5): 849-911.

[22] Pan W, Wang X, Xiao W, et al. A Generic Sure Independence Screening Procedure[J]. Journal of the American Statistical Association, 2019, 114(526): 928-937.

[23] Liu W, Ke Y, Liu J, et al. Model-Free Feature Screening and FDR Control With Knockoff Features[J]. Journal of the American Statistical Association, 2022, 117(537): 428-443.

[24] Jiang Y, Huang X, Tan J, et al. Robust feature screening via Grothendieck’s correlation with FDR control[J]. Statistics and Computing, 2025, 35(5): 141.

[25] Meinshausen N, Bühlmann P. Stability selection[J]. Journal of the Royal Statistical Society. Series B (Statistical Methodology), 2010, 72(4): 417-473.

[26] Fan J, Li R. Variable Selection via Nonconcave Penalized Likelihood and its Oracle Properties[J]. Journal of the American Statistical Association, 2001, 96(456): 1348-1360.

[27] King G, Zeng L. Logistic Regression in Rare Events Data[J]. Political Analysis, 2001, 9(2): 137-163.

[28] Breiman L. Statistical modeling:The two cultures[J]. Quality Control and Applied Statistics, 2003, (1): 48.

正文字符数（含空格）合计：15923 字。
下述附录仅给出关键代码，其余代码详见数据包

附录

附录

主要模型求解代码

```
cpp_source_code <- '
#include <Rcpp.h>
#include <cmath>
using namespace Rcpp;

// 直接传矩阵和列索引，避免反复创建 Rcpp 对象
void compute_kernel_matrix_optimized(const NumericMatrix& X, int col_idx, Numer-
icMatrix& A, NumericVector& norms, int n) {
  for(int i = 0; i < n; i++) {
        norms[i] = sqrt(X(i, col_idx) * X(i, col_idx) + 1.0);
  }
  double val, ratio;
  for(int i = 0; i < n; i++) {
    for(int j = 0; j <= i; j++) {
          val = X(i, col_idx) * X(j, col_idx) + 1.0;
          ratio = val / (norms[i] * norms[j]);
          if(ratio > 1.0) ratio = 1.0;
          if(ratio < -1.0) ratio = -1.0;
          double asin_val = std::asin(ratio);
          A(i, j) = asin_val;
          A(j, i) = asin_val;
    }
  }
```

```
}

void compute_kernel_matrix_Y(const NumericVector& y, NumericMatrix& A, Numer-
icVector& norms, int n) {
  for(int i = 0; i < n; i++) norms[i] = sqrt(y[i]*y[i] + 1.0);
  double val, ratio;
  for(int i = 0; i < n; i++) {
    for(int j = 0; j <= i; j++) {
        val = y[i]*y[j] + 1.0;
        ratio = val / (norms[i] * norms[j]);
        if(ratio > 1.0) ratio = 1.0;
        if(ratio < -1.0) ratio = -1.0;
        double asin_val = std::asin(ratio);
        A(i, j) = asin_val;
        A(j, i) = asin_val;
    }
  }
}

double center_and_sum_sq(NumericMatrix& A, int n, NumericVector& row_sums) {
  for(int i = 0; i < n; i++) A(i, i) = 0.0;
  double total_sum = 0.0;
  for(int i = 0; i < n; i++) {
    double r_sum = 0;
    for(int j = 0; j < n; j++) r_sum += A(i, j);
    row_sums[i] = r_sum;
    total_sum += r_sum;
  }
```

```
  double grand_mean = total_sum / ((n - 1.0) * (n - 2.0));
  double sq_sum = 0.0;
  for(int i = 0; i < n; i++) {
    double mean_i = row_sums[i] / (n - 2.0);
    for(int j = 0; j < n; j++) {
        if (i == j) { A(i, j) = 0.0; }
        else {
            double mean_j = row_sums[j] / (n - 2.0);
            double centered_val = A(i, j) - mean_i - mean_j + grand_mean;
            A(i, j) = centered_val;
            sq_sum += centered_val * centered_val;
        }
    }
  }
  return sq_sum;
}

// [[Rcpp::export]]
NumericVector GCor_SIS_cpp_loop(NumericMatrix X, NumericVector Y) {
    int p = X.ncol();
    int n = X.nrow();
    NumericVector results(p);

    // 缓冲区只分配一次
    NumericMatrix Mat_Buffer_Y(n, n);
    NumericMatrix Mat_Buffer_X(n, n);
    NumericVector Norms_Buffer(n);
    NumericVector RowSum_Buffer(n);
```

```
    compute_kernel_matrix_Y(Y, Mat_Buffer_Y, Norms_Buffer, n);
    double Y_sq_sum = center_and_sum_sq(Mat_Buffer_Y, n, RowSum_Buffer);
    if (Y_sq_sum == 0) return results;

    for(int j = 0; j < p; j++) {
        // 传列索引而非创建 X_col 对象，避免触发 R GC
        compute_kernel_matrix_optimized(X, j, Mat_Buffer_X, Norms_Buffer, n);
        double X_sq_sum = center_and_sum_sq(Mat_Buffer_X, n, RowSum_Buffer);
        if (X_sq_sum == 0) { results[j] = 0.0; }
        else {
            double num = 0.0;
            for(int i = 0; i < n * n; i++) { num += Mat_Buffer_X[i] * Mat_Buffer_Y[i]; }
            double cor = num / sqrt(X_sq_sum * Y_sq_sum);
            results[j] = cor * cor;
        }
    }
    return results;
}
'


# 核心单次筛选算法
GCor_SIS_REDS <- function(X, Y, alpha = 0.05) {
  n <- nrow(X)
  p <- ncol(X)

  # 划分 D1 和 D2 的索引
  n1 <- floor(2 * n / 3)
```

```
n2 <- n - n1
idx1 <- sample(1:n, n1)

# 内存优化：算完即销毁，逐段加载到内存
# 阶段 A：用 D1 计算
X1 <- X[idx1, , drop = FALSE]
Y1 <- Y[idx1]
omega1 <- GCor_SIS_cpp_loop(X1, Y1)
rm(X1, Y1)
gc()

# 阶段 B：用 D2 计算
X2 <- X[-idx1, , drop = FALSE]
Y2 <- Y[-idx1]
omega2 <- GCor_SIS_cpp_loop(X2, Y2)
rm(X2, Y2)
gc()

# 计算 M_r (公式 4)
term1 <- n1 * omega1
term2 <- n2 * omega2
M <- sign(term1 - term2) * pmax(term1, term2)

# 寻找 t_opt (公式 6)
t_candidates <- sort(unique(abs(M[M != 0])))
t_opt <- Inf

for (t in t_candidates) {
```

```
    numerator <- 1 + sum(M <= -t)
    denominator <- max(sum(M >= t), 1)

    if ((numerator / denominator) <= alpha) {
      t_opt <- t
      break
    }
  }

  # 获取活跃预测变量集
  if (is.infinite(t_opt)) {
    active_predictors <- integer(0)
  } else {
    active_predictors <- which(M >= t_opt)
  }

  return(list(
    selected = active_predictors,
    t_opt = t_opt,
    M_values = M
  ))
}

# 全量多重拆分算法
library(doParallel)
library(foreach)

GCor_SIS_REDS_MDS <- function(X, Y, alpha = 0.1, B = 20, tau = 0.5) {
```

```
  # 转为纯矩阵/向量，避免 Rcpp 因数据框属性额外复制大矩阵
  if (!is.matrix(X)) X <- unname(as.matrix(X))
  if (!is.numeric(Y)) Y <- unname(as.numeric(Y))

  p <- ncol(X)

  # 解除 R 核心数限制，预留 2 核给系统
  Sys.unsetenv("_R_CHECK_LIMIT_CORES_")
  n_cores <- 20

  cat(sprintf("启动纯并行全量 MDS，使用核心数: %d，共执行 %d 次拆分...\n",
n_cores, B))

  cl <- makeCluster(n_cores)

  # 向工作节点分发 C++ 代码
  clusterExport(cl, "cpp_source_code", envir = .GlobalEnv)
  clusterEvalQ(cl, {
    library(Rcpp)
    cppFunction(cpp_source_code)
  })

  registerDoParallel(cl)

  start_time <- Sys.time()

  # 执行并行多重拆分
```

```
  results_list <- foreach(b = 1:B,
                                    .packages = c("Rcpp"),
                                    .export = c("GCor_SIS_REDS")) %dopar% {

    res_single <- GCor_SIS_REDS(X, Y, alpha = alpha)
    return(res_single$selected)
  }

  stopCluster(cl)
  end_time <- Sys.time()

  cat(sprintf("全量并行计算完成！耗时: %.2f 秒\n", as.numeric(difftime(end_time,
start_time, units="secs"))))

  # 汇总选择次数
  selection_counts <- numeric(p)
  for (selected_vars in results_list) {
    if (length(selected_vars) > 0) {
      selection_counts[selected_vars] <- selection_counts[selected_vars] + 1
    }
  }

  selection_freq <- selection_counts / B
  final_selected <- which(selection_freq >= tau)

  cat(sprintf("全流程结束。最终从 %d 维全样本中严选出 %d 个特征。\n", p,
length(final_selected)))
  return(list(
```

```
    final_selected = final_selected,
    selection_freq = selection_freq
  ))
}



# 前期数据读取与全量 MDS
rm(list = ls())
gc()

source("GCor_SIS_REDS_MDS.R")
Sys.setenv(OPENBLAS_NUM_THREADS = 1)
Sys.setenv(OMP_NUM_THREADS = 1)
Sys.setenv(MKL_NUM_THREADS = 1)

train_data <- readRDS("02_Train_Ultrahigh.rds")
test_data  <- readRDS("02_Test_Ultrahigh.rds")

# 强制剥离名字等属性，避免内存冗余复制
X_train <- unname(as.matrix(train_data$X))
X_test  <- unname(as.matrix(test_data$X))
Y_train <- unname(as.numeric(as.character(train_data$Y)))
Y_test  <- unname(as.numeric(as.character(test_data$Y)))

print("已读取数据，正在启动 GCor_SIS_REDS_MDS 筛选...")

# 执行全量 MDS 筛选
selected_results <- GCor_SIS_REDS_MDS(X_train, Y_train,
```

```
                                        alpha = 0.1,
                                        B = 20,
                                        tau = 0.5)

### 【新增 1】：保存 SIS 阶段的核心结果 ###
saveRDS(selected_results, "03_SIS_Results_Full.rds")
print("SIS 阶段结果已保存至 03_SIS_Results_Full.rds")

# 提取最终筛选出的真实索引
selected_idx <- selected_results$final_selected
selection_freq <- selected_results$selection_freq

print(paste("最终筛选出的特征数量:", length(selected_idx)))
# print(paste("特征选择频率:", paste(round(selection_freq, 3), collapse = ", ")))

# 根据筛选出的索引提取子矩阵，供下一步 SCAD 模型使用
X_train_sis <- X_train[, selected_idx, drop = FALSE]
X_test_sis  <- X_test[, selected_idx, drop = FALSE]

# 确保 Y 必须是 0-1 因子或数值型 (1 代表破产，0 代表没破产)
Y_train_bin <- as.numeric(as.character(Y_train))
Y_test_bin  <- as.numeric(as.character(Y_test))

library(ggplot2)
library(dplyr)
library(ncvreg)
library(pROC)
library(caret)
```

```
library(PRROC)
library(ROCR)
library(patchwork)
library(brglm2)

theme_colors <- c("#c6c077", "#8aae76", "#59977a", "#377d79", "#2d636e", "#2f4858")
setwd("D:/codes/python_codes/26 统计建模")

# 加载数据并提取 SIS 筛选后的特征
sis_results <- readRDS("03_SIS_Results_Full.rds")
train_data  <- readRDS("02_Train_Ultrahigh.rds")
test_data   <- readRDS("02_Test_Ultrahigh.rds")

idx <- which(sis_results$selection_freq > 0.7)

# 绘制特征选择频次分布
freq_df <- data.frame(
  Feature = idx,
  Frequency = sis_results$selection_freq[idx]
)

p_freq_bar <- ggplot(freq_df, aes(x = Frequency)) +
  geom_histogram(breaks = seq(0.7, 1, by = 0.05),
                 fill = theme_colors[4], color = "white",
                 linewidth = 0.5, alpha = 0.85) +
  scale_x_continuous(breaks = seq(0.7, 1, by = 0.05), limits = c(0.68, 1.02)) +
  scale_y_continuous(labels = scales::label_number(accuracy = 1)) +
  theme_minimal(base_size = 14) +
```

```
  labs(title = "Distribution of Highly Stable Features",
       subtitle = "Selection frequency > 0.7 across screening iterations",
       x = "Selection Frequency (Interval = 0.05)",
       y = "Count (Number of Features)") +
  theme(panel.grid.minor = element_blank(),
        plot.title = element_text(face = "bold", size = 15),
        axis.text.x = element_text(angle = 45, hjust = 1))

print(p_freq_bar)

# 构建数据集并训练 SCAD 模型
X_train_sis <- as.matrix(train_data$X)[, idx, drop = FALSE]
X_test_sis  <- as.matrix(test_data$X)[, idx, drop = FALSE]
Y_train_bin <- as.numeric(as.character(train_data$Y))
Y_test_bin  <- as.numeric(as.character(test_data$Y))

set.seed(1)

n_0 <- sum(Y_train_bin == 0)
n_1 <- sum(Y_train_bin == 1)
weight_ratio <- n_0 / n_1
w <- ifelse(Y_train_bin == 1, weight_ratio, 1)

folds_index <- createFolds(Y_train_bin, k = 10, list = FALSE)

cv_scad <- cv.ncvreg(
  X = X_train_sis,
  y = Y_train_bin,
```

```
  family = "binomial",
  penalty = "SCAD",
  gamma = 3.7,
  nlambda = 150,
  eps = 0.01,
  fold = folds_index,
  max.iter = 10000,
  obs.weights = w,
  returnY = TRUE
)

best_lambda <- cv_scad$lambda.min
coef_scad <- coef(cv_scad)
active_vars <- sum(coef_scad[-1] != 0)

cat("\n[SCAD Model Summary]\n")
cat("Optimal lambda :", best_lambda, "\n")
cat("Active features:", active_vars, "\n")

saveRDS(cv_scad, "03_SCAD_Model.rds")

# 准备模型评估数据 (ROC, PR, KS, F 分数)
prob_pred <- predict(cv_scad, X_test_sis, type = "response")

# 计算 ROC 和 Youden 阈值
roc_obj <- roc(response = Y_test_bin, predictor = as.numeric(prob_pred),
                        levels = c(0, 1), direction = "<", quiet = TRUE)
auc_value <- auc(roc_obj)
```

```
best_thresh_info <- coords(roc_obj, "best", ret = c("threshold", "specificity", "sensitivity",
"accuracy"))
optimal_threshold <- best_thresh_info$threshold[1]

# 计算 PR 曲线
fg <- prob_pred[Y_test_bin == 1]
bg <- prob_pred[Y_test_bin == 0]
pr_obj <- pr.curve(scores.class0 = fg, scores.class1 = bg, curve = TRUE)
pr_auc_value <- pr_obj$auc.integral

# 计算 KS 统计量
pred_rocr <- prediction(prob_pred, Y_test_bin)
perf_tpr <- performance(pred_rocr, "tpr")
perf_fpr <- performance(pred_rocr, "fpr")
cutoffs <- perf_tpr@x.values[[1]]
tpr_vals <- perf_tpr@y.values[[1]]
fpr_vals <- perf_fpr@y.values[[1]]
ks_diff <- tpr_vals - fpr_vals
ks_stat <- max(ks_diff)
ks_index <- which.max(ks_diff)

# 计算混淆矩阵与 F 分数
class_pred <- factor(ifelse(prob_pred >= optimal_threshold, 1, 0), levels = c(0, 1))
Y_test_factor <- factor(Y_test_bin, levels = c(0, 1))
conf_matrix <- confusionMatrix(class_pred, Y_test_factor, positive = "1")

precision <- conf_matrix$byClass["Pos Pred Value"]
recall <- conf_matrix$byClass["Sensitivity"]
```

```
f1_score <- conf_matrix$byClass["F1"]


if(is.na(precision)) precision <- 0
if(is.na(recall)) recall <- 0


f2_score <- (1 + 2^2) * (precision * recall) / ((2^2 * precision) + recall)
if(is.na(f2_score)) f2_score <- 0


# 绘制 ROC 曲线
roc_df <- data.frame(FPR = 1 - roc_obj$specificities, TPR = roc_obj$sensitivities)
p_roc <- ggplot(roc_df, aes(x = FPR, y = TPR)) +
  geom_line(color = theme_colors[4], linewidth = 1.2) +
  geom_abline(slope = 1, intercept = 0, linetype = "dashed", color = "gray") +
  theme_minimal(base_size = 14) +
  labs(title = "ROC Curve", subtitle = sprintf("AUC = %.4f", auc_value),
       x = "False Positive Rate", y = "True Positive Rate") +
  theme(panel.grid.minor = element_blank(), plot.title = element_text(face = "bold", size
= 15))


# 绘制 Precision-Recall 曲线
pr_df <- data.frame(Recall = pr_obj$curve[, 1], Precision = pr_obj$curve[, 2])
p_pr <- ggplot(pr_df, aes(x = Recall, y = Precision)) +
  geom_line(color = theme_colors[5], linewidth = 1.2) +
  theme_minimal(base_size = 14) +
   labs(title = "Precision-Recall Curve", subtitle = sprintf("PR-AUC = %.4f",
pr_auc_value),
       x = "Recall (Sensitivity)", y = "Precision (PPV)") +
```

```
  theme(panel.grid.minor = element_blank(), plot.title = element_text(face = "bold", size = 15))

# 绘制 KS 曲线
ks_df <- data.frame(Threshold = cutoffs, TPR = tpr_vals, FPR = fpr_vals)
p_ks <- ggplot(ks_df, aes(x = Threshold)) +
  geom_line(aes(y = TPR, color = "TPR"), linewidth = 1.2) +
  geom_line(aes(y = FPR, color = "FPR"), linewidth = 1.2) +
  geom_vline(xintercept = cutoffs[ks_index], linetype = "dashed", color = "black") +
  scale_color_manual(name = "Metrics", values = c("TPR" = theme_colors[4], "FPR" = theme_colors[2])) +
  theme_minimal(base_size = 14) +
  labs(title = "KS Curve", subtitle = sprintf("KS Statistic = %.4f", ks_stat),
       x = "Probability Threshold", y = "Cumulative Rate") +
  theme(panel.grid.minor = element_blank(), plot.title = element_text(face = "bold", size = 15), legend.position = "bottom")

# 绘制校准曲线
calib_data <- data.frame(
  obs = factor(ifelse(Y_test_bin == 1, "Bankruptcy", "Healthy"), levels = c("Bankruptcy", "Healthy")),
  Bankruptcy = prob_pred
)
calib_obj <- calibration(obs ~ Bankruptcy, data = calib_data, class = "Bankruptcy", cuts = 10)
calib_df <- calib_obj$data

p_calib <- ggplot(calib_df, aes(x = midpoint, y = Percent)) +
```

```
  geom_line(color = theme_colors[6], linewidth = 1.2) +
  geom_point(color = theme_colors[6], size = 3) +
  geom_abline(slope = 1, intercept = 0, linetype = "dashed", color = "gray") +
  theme_minimal(base_size = 14) +
  labs(title = "Calibration Curve (Reliability Diagram)",
       x = "Bin Midpoint (Predicted Probability %)", y = "Observed Event Percentage (%)") +
  theme(panel.grid.minor = element_blank(), plot.title = element_text(face = "bold", size = 15))

# 绘制特征系数重要性图（编号映射避免长变量名）
all_coefs <- coef(cv_scad)
active_coefs <- all_coefs[-1][all_coefs[-1] != 0]

if(length(active_coefs) > 0) {
  coef_df <- data.frame(Feature_Name = names(active_coefs), Coefficient = active_coefs)
  coef_df <- coef_df[order(abs(coef_df$Coefficient), decreasing = TRUE), ]

  # 生成两位数编号 (F01, F02...)
  num_active <- nrow(coef_df)
  coef_df$Feature_ID <- paste0("F", sprintf("%02d", 1:num_active))

  coef_df$Feature_ID <- factor(coef_df$Feature_ID, levels = coef_df$Feature_ID)

  # 提取编号-原始名映射表供报告使用
  feature_mapping_table <- coef_df[, c("Feature_ID", "Feature_Name", "Coefficient")]

  p_coef <- ggplot(coef_df, aes(x = Feature_ID, y = Coefficient, fill = Coefficient > 0)) +
```

```
    geom_bar(stat = "identity", width = 0.6) +
    scale_fill_manual(values = c("TRUE" = theme_colors[4], "FALSE" = theme_colors[2]), guide = "none") +
    coord_flip() +
    theme_minimal(base_size = 14) +
    labs(title = "SCAD Feature Importance (Mapped)",
         subtitle = "See table below for feature definitions",
         x = "Feature ID", y = "Coefficient Value") +
    theme(panel.grid.minor = element_blank(),
          plot.title = element_text(face = "bold", size = 15))

  print(p_coef)

  cat("\n--- SCAD Feature ID Mapping Table ---\n")
  print(feature_mapping_table, row.names = FALSE)
  cat("----------------------------------------\n")
}

# 组合并输出所有评估图表
p_combined <- (p_roc | p_pr) /
  (p_ks | p_calib) +
  plot_annotation(
    title = "Comprehensive Model Evaluation Metrics",
    theme = theme(plot.title = element_text(face = "bold", size = 18, hjust = 0.5))
  )
print(p_combined)
if(exists("p_coef")) print(p_coef)
```

```
# 构建模型评估指标汇总表
eval_metrics_df <- data.frame(
  Metric = c("ROC-AUC", "PR-AUC", "KS Statistic", "Optimal Threshold",
             "Precision (PPV)", "Recall (Sensitivity)", "F1-Score", "F2-Score"),
  Value = round(c(auc_value, pr_auc_value, ks_stat, optimal_threshold,
                  precision, recall, f1_score, f2_score), 4)
)

# 后选择推断：SCAD 筛选后拟合标准 Logistic 回归并计算置信区间
# SCAD 完成高维变量筛选后，对选中的变量拟合标准 Logistic 回归，
# 获得系数估计、标准误、p 值、置信区间。
# 检测"分离"变量 (Std_Error > 10) 并标记其不可靠性，不强行使用 brglm2 导致全局退化。

# 核心推断函数：SCAD 筛选 → 标准 Logistic 回归 → Bootstrap 验证
post_scad_inference <- function(cv_scad_obj, X_train, y_train, weights = NULL,
                                alpha = 0.05, bootstrap = TRUE, n_boot = 200,
                                se_threshold = 10) {

  coef_all <- coef(cv_scad_obj)
  active_idx <- which(coef_all[-1] != 0)

  # 按 SCAD 系数绝对值降序排列
  coef_nonzero <- coef_all[-1][active_idx]
  active_idx <- active_idx[order(abs(coef_nonzero), decreasing = TRUE)]

  if (length(active_idx) == 0) {
    cat("SCAD selected no variables. Inference skipped.\n")
```

```
    return(NULL)
}

n_selected_initial <- length(active_idx)
cat(sprintf("SCAD selected %d variables. Fitting standard logistic...\n",
                    n_selected_initial))

X_selected <- X_train[, active_idx, drop = FALSE]

# 生成短变量名映射 (F01, F02, ...)
var_mapping <- data.frame(
    ShortID    = paste0("F", sprintf("%02d", seq_along(active_idx))),
    Original = colnames(X_selected),
    stringsAsFactors = FALSE
)

df <- data.frame(y = y_train, X_selected)

# 第一轮：全变量 glm，检测共线别名化和分离退化
fit_glm_all <- if (!is.null(weights)) {
    glm(y ~ ., data = df, family = binomial, weights = weights)
} else {
    glm(y ~ ., data = df, family = binomial)
}

s_all <- summary(fit_glm_all)$coefficients
var_names_all <- rownames(s_all)
se_all <- s_all[, "Std. Error"]
```

```
# 标记别名化变量（glm 因共线自动丢弃）和标准误过大的变量（分离信号）
var_in_model_all <- var_names_all[var_names_all != "(Intercept)"]
aliased_vars <- setdiff(colnames(X_selected), var_in_model_all)
unstable_vars <- var_in_model_all[
  sapply(var_in_model_all, function(vn) {
    idx <- which(rownames(s_all) == vn)
    length(idx) > 0 && (se_all[idx] > se_threshold || is.na(se_all[idx]))
  })
]
vars_to_remove <- c(aliased_vars, unstable_vars)

if (length(vars_to_remove) > 0) {
  remove_mask <- var_mapping$Original %in% vars_to_remove
  cat(sprintf("    Removed %d variable(s) (aliased or Std_Error > %d): %s\n",
              length(vars_to_remove), se_threshold,
              paste(var_mapping$ShortID[remove_mask], collapse = ", ")))
  cat("    Refitting standard logistic on reduced variable set...\n")

  keep <- !remove_mask
  active_idx <- active_idx[keep]
  X_selected <- X_selected[, keep, drop = FALSE]
  var_mapping <- var_mapping[keep, , drop = FALSE]

  df <- data.frame(y = y_train, X_selected)
  fit_glm <- if (!is.null(weights)) {
    glm(y ~ ., data = df, family = binomial, weights = weights)
  } else {
```

```
        glm(y ~ ., data = df, family = binomial)
    }
} else {
    fit_glm <- fit_glm_all
}

# 从标准 Logistic 回归提取系数推断结果
s <- summary(fit_glm)$coefficients
var_names <- rownames(s)
# 用短 ID 替代原始长变量名
for (i in seq_along(var_names)) {
    if (var_names[i] != "(Intercept)") {
        matched <- which(var_mapping$Original == var_names[i])
        if (length(matched) > 0) var_names[i] <- var_mapping$ShortID[matched]
    }
}
est <- s[, "Estimate"]
se   <- s[, "Std. Error"]
z_val <- s[, "z value"]
p_val <- s[, "Pr(>|z|)"]

# 第二轮分离诊断（应无异常）
unstable_flag <- se > se_threshold | is.na(se)
if (any(unstable_flag)) {
    cat("    Refit still has Std_Error >", se_threshold, ":",
            paste(var_names[unstable_flag], collapse = ", "), "\n")
}
```

```
z_crit <- qnorm(1 - alpha / 2)
ci_lower <- est - z_crit * se
ci_upper <- est + z_crit * se

# Bootstrap 验证（在无惩罚模型上进行）
boot_ci_lower <- boot_ci_upper <- rep(NA, length(est))
names(boot_ci_lower) <- names(boot_ci_upper) <- var_names

if (bootstrap) {
  cat(sprintf("Bootstrap validation on refitted model (B = %d)...\n", n_boot))
  boot_coefs <- matrix(NA, n_boot, length(est))
  colnames(boot_coefs) <- var_names

  for (b in seq_len(n_boot)) {
    idx <- sample(nrow(X_train), replace = TRUE)
    df_boot <- data.frame(y = y_train[idx], X_selected[idx, , drop = FALSE])

    tryCatch({
      w_boot <- if (!is.null(weights)) weights[idx] else NULL
      boot_fit <- if (!is.null(w_boot)) {
        glm(y ~ ., data = df_boot, family = binomial, weights = w_boot)
      } else {
        glm(y ~ ., data = df_boot, family = binomial)
      }
      boot_coefs[b, ] <- coef(boot_fit)
    }, error = function(e) {
      # 标准 glm 因分离失败时降级为 brglm2
      tryCatch({
```

```
            boot_fit <- if (!is.null(w_boot)) {
              glm(y ~ ., data = df_boot, family = binomial,
                  weights = w_boot, method = "brglmFit")
            } else {
              glm(y ~ ., data = df_boot, family = binomial,
                  method = "brglmFit")
            }
            boot_coefs[b, ] <- coef(boot_fit)
          }, error = function(e2) {
            boot_coefs[b, ] <- NA
          })
        })

        if (b %% 50 == 0) cat(sprintf("    Bootstrap %d / %d\n", b, n_boot))
      }

      for (i in seq_along(est)) {
        s_i <- boot_coefs[, i]
        s_i <- s_i[!is.na(s_i)]
        if (length(s_i) > 0) {
          boot_ci_lower[i] <- quantile(s_i, alpha / 2, na.rm = TRUE)
          boot_ci_upper[i] <- quantile(s_i, 1 - alpha / 2, na.rm = TRUE)
        }
      }
    }

    # 组装结果
    results <- data.frame(
```

```
    Variable                = var_names,
    Coefficient             = round(est, 5),
    Std_Error               = round(se, 5),
    Z_Statistic             = round(z_val, 4),
    P_Value                 = round(p_val, 5),
    Significant             = p_val < alpha,
    Odds_Ratio              = round(exp(est), 4),
    OR_CI_Lower             = round(exp(ci_lower), 4),
    OR_CI_Upper             = round(exp(ci_upper), 4),
    Analytic_CI_Lower = round(ci_lower, 5),
    Analytic_CI_Upper = round(ci_upper, 5),
    Bootstrap_CI_Lower = round(boot_ci_lower, 5),
    Bootstrap_CI_Upper = round(boot_ci_upper, 5),
    stringsAsFactors    = FALSE
  )

  attr(results, "selected_idx")       <- active_idx
  attr(results, "glm_fit")             <- fit_glm
  attr(results, "var_mapping")         <- var_mapping
  attr(results, "n_scad_selected") <- n_selected_initial
  return(results)
}

# 执行后选择推断
cat("Post-Selection Significance Testing\n")
cat("Pipeline: SIS screening -> SCAD selection -> Standard logistic refit\n")
cat("                (Bootstrap with brglm2 fallback for separation)\n\n")
```

```
inference_results <- post_scad_inference(
  cv_scad, X_train_sis, Y_train_bin,
  weights = w, bootstrap = TRUE, n_boot = 200
)

# 推断成功时展示结果并绘图
if (!is.null(inference_results)) {

  cat("\n====== Post-SCAD Inference Results ======\n")
  print(inference_results, row.names = FALSE)

  # 打印短 ID 与原始变量名映射
  var_map <- attr(inference_results, "var_mapping")
  if (!is.null(var_map)) {
    cat("\n--- Variable ID Mapping (short ID -> original name) ---\n")
    print(var_map, row.names = FALSE)
    cat("-----------------------------------------------------\n")
  }

  # 显著性汇总（排除截距项）
  has_intercept <- any(inference_results$Variable == "(Intercept)")
  n_features <- nrow(inference_results) - as.integer(has_intercept)
  sig_flag <- inference_results$Significant
  cat(sprintf("\nSignificant at alpha = 0.05 :  %d / %d variables\n",
              sum(sig_flag[inference_results$Variable != "(Intercept)"]), n_features))
  if (sum(sig_flag) > 0) {
    cat("Significant:", paste(inference_results$Variable[sig_flag], collapse = ", "), "\n")
  }
```

```
# 置信区间可视化（排除截距项）
has_intercept <- any(inference_results$Variable == "(Intercept)")
plot_data <- inference_results
if (has_intercept) plot_data <- plot_data[plot_data$Variable != "(Intercept)", ]

if (nrow(plot_data) > 0) {

  # 系数图 + 解析 CI
  plot_data$Variable <- reorder(plot_data$Variable, plot_data$Coefficient)

  p_analytic <- ggplot(plot_data, aes(x = Variable, y = Coefficient)) +
    geom_point(aes(color = Significant), size = 3) +
    geom_errorbar(aes(ymin = Analytic_CI_Lower, ymax = Analytic_CI_Upper,
                      color = Significant), width = 0.2) +
    geom_hline(yintercept = 0, linetype = "dashed", color = "red") +
      scale_color_manual(values = c("TRUE" = theme_colors[4], "FALSE" =
theme_colors[2]),
                         labels = c("Significant", "Not Significant")) +
    coord_flip() + theme_minimal(base_size = 14) +
    labs(title = "Post-SCAD Coefficients (Unpenalized Refit)",
         subtitle = "95% Confidence Intervals (Wald)",
         x = "Variable", y = "Coefficient (Log-Odds)") +
    theme(panel.grid.minor = element_blank(),
          plot.title = element_text(face = "bold", size = 15),
          legend.position = "bottom")
  print(p_analytic)
```

```
    # 优势比森林图
    p_or <- ggplot(plot_data, aes(x = Variable, y = Odds_Ratio)) +
      geom_point(aes(color = Significant), size = 3) +
      geom_errorbar(aes(ymin = OR_CI_Lower, ymax = OR_CI_Upper,
                        color = Significant), width = 0.2) +
      geom_hline(yintercept = 1, linetype = "dashed", color = "red") +
        scale_color_manual(values = c("TRUE" = theme_colors[4], "FALSE" =
theme_colors[2]),
                           labels = c("Significant", "Not Significant")) +
      coord_flip() + theme_minimal(base_size = 14) +
      labs(title = "Odds Ratios with 95% Confidence Intervals",
           subtitle = "OR > 1 -> positive association with outcome",
           x = "Variable", y = "Odds Ratio") +
      theme(panel.grid.minor = element_blank(),
            plot.title = element_text(face = "bold", size = 15),
            legend.position = "bottom")
    print(p_or)

    # Bootstrap CI（若有）
    if (any(!is.na(plot_data$Bootstrap_CI_Lower))) {
      p_boot <- ggplot(plot_data, aes(x = Variable, y = Coefficient)) +
        geom_point(aes(color = Significant), size = 3) +
        geom_errorbar(aes(ymin = Bootstrap_CI_Lower, ymax = Bootstrap_CI_Upper,
                          color = Significant), width = 0.2, alpha = 0.7) +
        geom_hline(yintercept = 0, linetype = "dashed", color = "red") +
          scale_color_manual(values = c("TRUE" = theme_colors[5], "FALSE" =
theme_colors[3]),
                             labels = c("Significant", "Not Significant")) +
```

```
        coord_flip() + theme_minimal(base_size = 14) +
        labs(title = "Bootstrap-Validated Confidence Intervals",
             subtitle = "95% Bootstrap Percentile CI (B = 200)",
             x = "Variable", y = "Coefficient (Log-Odds)") +
        theme(panel.grid.minor = element_blank(),
              plot.title = element_text(face = "bold", size = 15),
              legend.position = "bottom")
      print(p_boot)
    }
  }

  # 模型稳定性评估
  cat("\n=== Model Stability (Bootstrap vs Analytic CI) ===\n")
  if (any(!is.na(inference_results$Bootstrap_CI_Lower))) {
    ci_comp <- data.frame(
      Variable        = inference_results$Variable,
      Analytic_Width = inference_results$Analytic_CI_Upper - inference_results$Analytic_CI_Lower,
       Bootstrap_Width = inference_results$Bootstrap_CI_Upper - inference_results$Bootstrap_CI_Lower
    )
    ci_comp$Width_Ratio <- ci_comp$Bootstrap_Width / ci_comp$Analytic_Width
    cat("CI width comparison:\n")
    print(ci_comp, row.names = FALSE)

    avg_ratio <- mean(ci_comp$Width_Ratio, na.rm = TRUE)
    cat(sprintf("Average Bootstrap/Analytic width ratio: %.3f\n", avg_ratio))
    if (avg_ratio > 1.2) {
```

```
        cat("-> Bootstrap CIs are wider -> model may be slightly unstable.\n")
    } else if (avg_ratio < 0.8) {
        cat("-> Bootstrap CIs are narrower.\n")
    } else {
        cat("-> Bootstrap & Analytic CIs are consistent -> model appears stable.\n")
    }
}

# 保存推断结果
saveRDS(inference_results, "03_SCAD_Inference_Results.rds")

# 推断报告
cat("\n")
cat("POST-SCAD STATISTICAL INFERENCE REPORT\n")

cat("\n[1. Model Performance]\n")
print(eval_metrics_df, row.names = FALSE)

n_vars <- nrow(inference_results) - as.integer(has_intercept)
n_scad_total <- attr(inference_results, "n_scad_selected")
if (is.null(n_scad_total)) n_scad_total <- n_vars
cat(sprintf("\n[2. Variable Selection]\n"))
cat(sprintf("    SCAD selected                : %d features\n", n_scad_total))
if (n_scad_total != n_vars) {
    cat(sprintf("    After instability removal: %d features\n", n_vars))
}
cat(sprintf("    Significant        : %d (at alpha = 0.05)\n",
                  sum(sig_flag[inference_results$Variable != "(Intercept)"])))
```

```
  cat("\n[3. Coefficient Interpretation]\n")
  cat("    Coefficients are in log-odds scale.\n")
  cat("    Odds Ratio (OR) = exp(coef).    OR > 1 -> positive association.\n")
  cat("    A 95% CI that excludes 0 (log-odds) or 1 (OR) indicates significance.\n")

  glm_fit <- attr(inference_results, "glm_fit")
  cat(sprintf("\n[4. Refit Diagnostics]\n"))
   cat(sprintf("    Residual deviance : %.2f on %d df\n", deviance(glm_fit), df.resid-
ual(glm_fit)))
  cat(sprintf("    AIC                          : %.2f\n", AIC(glm_fit)))

} else {
  cat("Inference calculation failed. Check model convergence and data quality.\n")
}

# 输出混淆矩阵并保存评估指标
cat("\n--- Confusion Matrix (Optimal Threshold) ---\n")
print(conf_matrix$table)
cat("\n")

save(prob_pred, roc_obj, pr_obj, conf_matrix, eval_metrics_df, Y_test_bin,
       inference_results, cv_scad,
       file = "03_Evaluation_Metrics.RData")
```